Clasificación global de fracturas cervicales en tomografía computarizada a partir de una muestra de RSNA 2022

Pablo Andrés Cabrera (231156) Hansel André López (19026)
Pablo José Méndez (23975) María José Yee (231193)

Universidad del Valle de Guatemala — CC3084 Data Science
Guatemala, octubre de 2026

Resumen

La detección de fracturas cervicales mediante tomografía computarizada constituye un problema relevante en el análisis de imágenes médicas debido a las posibles complicaciones neurológicas asociadas con estas lesiones y a la complejidad de su identificación. El presente trabajo tuvo como objetivo implementar y evaluar un sistema de clasificación automática capaz de estimar la presencia de al menos una fractura cervical por estudio, utilizando el conjunto de datos RSNA 2022 Cervical Spine Fracture Detection.

Se desarrolló un *pipeline* de preprocesamiento de imágenes DICOM que incluyó conversión a unidades Hounsfield, aplicación de una ventana ósea, normalización, redimensionamiento y ordenamiento anatómico de los cortes. Se procesaron 2,019 estudios, distribuidos en 1,292 para entrenamiento, 323 para validación y 404 para prueba. Se implementaron dos arquitecturas de aprendizaje profundo: ResNet18 con aprendizaje de múltiples instancias (MIL) y ResNet18 combinada con una unidad recurrente bidireccional (BiGRU). Ambos modelos utilizaron representaciones 2.5D de 48 posiciones tomográficas por estudio y fueron evaluados mediante métricas de clasificación y comparación estadística.

En el conjunto de prueba, ResNet18 + MIL obtuvo un ROC-AUC de 0.638 y un F1-score de 0.465, mientras que ResNet18 + BiGRU alcanzó un ROC-AUC de 0.737 y un F1-score de 0.632. La diferencia de ROC-AUC favoreció a BiGRU y resultó estadísticamente significativa mediante la prueba de DeLong ($p < 0.001$). Adicionalmente, el análisis exploratorio identificó variaciones en los parámetros de adquisición DICOM, especialmente en el reescalado de intensidades, el espaciado de píxeles y el orden anatómico de los cortes.

Se concluye que la incorporación de información secuencial mediante BiGRU produjo una mejora en la capacidad discriminativa respecto al modelo MIL evaluado. No obstante, el desempeño absoluto continúa siendo moderado y el sistema se limita a clasificación global por estudio, sin localizar las fracturas ni identificar las vértebras afectadas. Por tanto, los resultados constituyen una aproximación experimental reproducible que requiere optimización adicional y validación externa antes de considerar cualquier aplicación clínica.

Palabras clave: fracturas cervicales, tomografía computarizada, DICOM, aprendizaje profundo, ResNet18, MIL, BiGRU, clasificación de imágenes médicas.

Índice general

1 Introducción **3**

1.1 Problema científico 3

2 Objetivos **3**

2.1 Objetivo general 3
2.2 Objetivos específicos 3

3 Marco teórico **3**
3.1 Tomografía computarizada, DICOM y unidades Hounsfield 3
3.2 Procesamiento de imágenes médicas 4
3.3 Análisis de las imágenes desde el punto de vista médico 4
3.4 Algoritmos de aprendizaje profundo 4
3.5 Evaluación 4

4 Metodología **4**
4.1 Pasos seguidos por el grupo 4
4.2 Datos y particiones 5
4.3 Preprocesamiento 5
4.4 Herramientas y recursos de cómputo 5
4.5 Selección de algoritmos, arquitecturas y configuración de entrenamiento 5

5 Resultados y análisis de resultados **7**
5.1 Características del conjunto de datos original 7
5.2 Limpieza y preprocesamiento 7
5.3 Análisis exploratorio de las imágenes DICOM 7
5.4 Ajuste de parámetros 11
5.5 Comparación de algoritmos 12
5.6 Aplicación desarrollada 13

6 Conclusiones **19**

A Estado de integración del informe (uso interno; eliminar antes de entregar) **22**

1 Introducción

Las fracturas de la columna cervical son lesiones potencialmente graves: un diagnóstico tardío puede asociarse a deterioro neurológico. En pacientes adultos con trauma, la tomografía computarizada (TC) es la modalidad de imagen de referencia para su evaluación, y la decisión de solicitarla suele apoyarse en reglas clínicas como NEXUS (Hoffman et al., 2000) y la Canadian C-Spine Rule (Stiell et al., 2001). La lectura de cientos de cortes por estudio es demandante y motivó la competencia **RSNA 2022 Cervical Spine Fracture Detection** (Radiological Society of North America, 2022), cuyo conjunto de datos describen Lin et al. (2023).

Este informe continúa el análisis exploratorio del Proyecto 2 (datos tabulares `train.csv` y `train_bounding_boxes.csv`) y lo extiende con un experimento de aprendizaje profundo reproducible sobre las imágenes DICOM, ejecutado en Kaggle Notebooks por el tamaño del conjunto de datos.

1.1 Problema científico

¿Es posible construir, con recursos de cómputo acotados y una muestra reproducible de estudios de TC de RSNA 2022, un clasificador que estime **a nivel de estudio** la presencia de al menos una fractura cervical (`patient_overall`), y aporta el modelado secuencial de los cortes (BiGRU) una mejora medible frente a una agregación MIL simple?

2 Objetivos

2.1 Objetivo general

Implementar y evaluar, sobre estudios no vistos, un *pipeline* reproducible de preprocesamiento DICOM y clasificación global de fracturas cervicales en TC, y caracterizar la calidad y heterogeneidad de las imágenes que lo alimentan.

2.2 Objetivos específicos

1. Construir una muestra estratificada de 2 019 estudios con particiones por estudio sin fuga (entrenamiento 1 292, validación 323, prueba 404).
2. Implementar el preprocesamiento DICOM (HU, ventana ósea, normalización, 224×224, orden por `ImagePositionPatient`) y auditar la variabilidad de metadatos y su calidad.
3. Entrenar y evaluar ResNet18 + MIL y ResNet18 + BiGRU con las mismas particiones, reportando sensibilidad, especificidad, precisión, F1, exactitud y ROC-AUC con IC 95 %.
4. Seleccionar un modelo con base en resultados de validación y prueba, explicitando la incertidumbre.
5. Desarrollar una aplicación Streamlit que use el mismo preprocesamiento para inferencia.

3 Marco teórico

3.1 Tomografía computarizada, DICOM y unidades Hounsfield

Los estudios se distribuyen en formato DICOM: cada corte axial es un archivo cuya cabecera incluye parámetros de adquisición (`SliceThickness`, `PixelSpacing`, `Rows`/`Columns`, `RescaleSlope`/`RescaleIntercept`, `ImagePositionPatient`, sintaxis de transferencia, etc.). Los

valores de píxel se convierten a unidades Hounsfield (HU) con

$$\text{HU} = \text{valor} \times \texttt{RescaleSlope} + \texttt{RescaleIntercept}.$$

El aire ronda -1000 HU, el agua 0 HU y el hueso cortical supera varios cientos de HU. El *windowing* recorta el intervalo $[L - W/2,\ L + W/2]$ para maximizar el contraste del tejido de interés; aquí se usa una ventana ósea $L = 400$, $W = 1800$ (rango $[-500, 1300]$ HU).

3.2 Procesamiento de imágenes médicas

La heterogeneidad entre instituciones (grosor de corte, tamaño de píxel, protocolo de reescalado, orden de los cortes) obliga a estandarizar la entrada antes de cualquier modelo. Las decisiones de estandarización de este trabajo y su justificación empírica se discuten en la sección 5.3.

3.3 Análisis de las imágenes desde el punto de vista médico

PENDIENTE — Anatomía cervical y fracturas C1–C7

Descripción de las siete vértebras cervicales, mecanismos y patrones de fractura y signos radiológicos relevantes en TC, con referencias indexadas.

Fuente esperada: Documento de revisión bibliográfica del equipo (`revision_bibliografica_fracturas_cervicales.docx`); no se incluye en el repositorio, por lo que su contenido debe integrarse con la fuente original.

3.4 Algoritmos de aprendizaje profundo

Redes residuales. ResNet (He et al., 2016) introduce conexiones residuales que facilitan entrenar redes profundas; una ResNet18 preentrenada en ImageNet (Deng et al., 2009) es un extractor de características ligero. **Aprendizaje de múltiples instancias (MIL).** Con etiqueta solo a nivel de "bolsa" (estudio) y no de "instancia" (corte), MIL agrega puntuaciones de instancias en una puntuación de bolsa (Ilse et al., 2018); un estudio positivo puede tener la mayoría de cortes sin fractura visible, por lo que conviene agregar con los k logits más altos. **Modelos secuenciales.** Una GRU (Cho et al., 2014) bidireccional procesa la secuencia de *embeddings* de cortes ordenados por z en ambos sentidos, pudiendo capturar contexto anatómico entre cortes vecinos.

3.5 Evaluación

El ROC-AUC resume la discriminación independiente del umbral (Hanley and McNeil, 1982); el umbral operativo se fija con el índice de Youden $J = \text{sensibilidad} + \text{especificidad} - 1$ (Youden, 1950) en validación, y la incertidumbre del AUC se estima con *bootstrap* percentil (Efron and Tibshirani, 1993).

4 Metodología

4.1 Pasos seguidos por el grupo

1. Análisis exploratorio de los datos tabulares (Proyecto 2, primera entrega).
2. Revisión bibliográfica y selección de algoritmos.

3. Preprocesamiento DICOM y auditoría de metadatos (EDA de imágenes, sección 5.3).
4. Entrenamiento y evaluación de dos modelos con las mismas particiones.
5. Comparación estadística, selección y desarrollo de la aplicación interactiva.

4.2 Datos y particiones

Se usan `train.csv` (2 019 estudios; `patient_overall` y C1–C7) y las imágenes DICOM de la competencia (Radiological Society of North America, 2022). El volumen del conjunto de imágenes (del orden de cientos de GB) llevó a procesar los estudios dentro de Kaggle Notebooks, sin descargarlos localmente. La muestra comprende los 2 019 estudios, estratificados por `patient_overall` (semilla 42), con particiones *por estudio*: entrenamiento 1 292 (615 positivos), validación 323 (154) y prueba 404 (192); en RSNA 2022 cada estudio corresponde a un paciente distinto, por lo que no hay pacientes compartidos entre particiones.

4.3 Preprocesamiento

Paso	Implementación
Lectura	`pydicom`; decodificación JPEG Lossless con `pylibjpeg`/GDCM
Intensidades	HU = píxel × `RescaleSlope` + `RescaleIntercept`, leídos por archivo
Fotometría	MONOCHROME1 invertido; MONOCHROME2 sin cambios
Ventana	ósea $L = 400$, $W = 1800$, normalización lineal a $[0, 1]$
Tamaño	224×224 (`INTER_AREA`), sin remuestreo isotrópico
Selección de cortes	48 posiciones equiespaciadas entre el 5 % y el 95 % del rango de instancias; entrada 2.5D con vecinos a ±2 mm
Orden	por `ImagePositionPatient[2]` (z) ascendente, no por número de instancia

Cuadro 1: Pipeline de preprocesamiento (configuración v2, `artifacts/v2/config/preprocessing.json`).

4.4 Herramientas y recursos de cómputo

El entrenamiento se ejecutó en Kaggle Notebooks con GPU T4. Se usaron Python, `pydicom`, OpenCV, PyTorch (Paszke et al., 2019), Streamlit y Plotly; las versiones exactas están en `experimento_dl/requirements.txt`.

4.5 Selección de algoritmos, arquitecturas y configuración de entrenamiento

Para abordar la clasificación global de fracturas cervicales se seleccionaron dos arquitecturas de aprendizaje profundo que comparten un extractor de características visuales, pero difieren en el mecanismo utilizado para integrar la información de los cortes tomográficos. Esta selección permite comparar una estrategia de agregación basada en aprendizaje de múltiples instancias (*Multiple Instance Learning*, MIL) con un enfoque de modelado secuencial mediante una unidad recurrente cerrada bidireccional (*Bidirectional Gated Recurrent Unit*, BiGRU). Ambos modelos fueron diseñados para estimar la probabilidad de presencia de al menos una fractura cervical por estudio, correspondiente a la etiqueta `patient_overall`.

En ambas arquitecturas se utilizó ResNet18 preentrenada sobre ImageNet como extractor de características. Se eliminó su capa de clasificación original para obtener una representación de 512 características por posición tomográfica. Esta elección permite aprovechar representaciones visuales previamente aprendidas y utilizar una arquitectura relativamente compacta frente a

alternativas de mayor complejidad computacional. Los dos modelos recibieron entradas con dimensiones de $48 \times 3 \times 224 \times 224$ por estudio, correspondientes a 48 posiciones distribuidas entre el 5 % y el 95 % del rango de cortes, cada una representada mediante tres imágenes: el corte central y dos cortes vecinos situados aproximadamente a ± 2 mm.

El primer modelo, ResNet18 + MIL, aplica una capa de *dropout* con probabilidad de 0.3 y una transformación lineal de 512 características a un logit para cada posición. La predicción global se obtiene calculando el promedio de los tres logits más altos del estudio. Esta estrategia permite que las regiones con mayor evidencia estimada de fractura tengan mayor influencia en la decisión global, sin exigir que todos los cortes de un estudio positivo contengan signos visibles de lesión. El modelo dispone de 11,177,025 parámetros entrenables.

El segundo modelo, ResNet18 + BiGRU, utiliza las representaciones de 512 características extraídas por ResNet18 como una secuencia ordenada según la coordenada anatómica `ImagePositionPatient`. La GRU bidireccional incorpora 128 unidades ocultas por dirección, permitiendo procesar la secuencia en ambos sentidos. Posteriormente, se combinan las representaciones mediante operaciones de promedio y máximo, obteniendo un vector de 512 características que se introduce en una capa de *dropout* de 0.3 y una capa lineal de clasificación. Esta arquitectura contiene 11,670,081 parámetros entrenables y permite incorporar información contextual entre posiciones tomográficas.

Para asegurar una comparación experimental consistente, ambos modelos utilizaron las mismas particiones de datos: 1,292 estudios para entrenamiento, 323 para validación y 404 para prueba, con semilla aleatoria 42. También compartieron el preprocesamiento DICOM, consistente en conversión de intensidades a unidades Hounsfield, aplicación de una ventana ósea de nivel 400 y ancho 1800, normalización, redimensionamiento a 224×224 y ordenamiento anatómico de los cortes. Antes de introducir las imágenes en ResNet18, se aplicó la normalización correspondiente a ImageNet.

El entrenamiento utilizó la función de pérdida binaria `BCEWithLogitsLoss`, con un peso para la clase positiva de aproximadamente 1.1008, calculado a partir de la relación entre los 677 estudios negativos y los 615 positivos del conjunto de entrenamiento. Se empleó el optimizador AdamW con regularización por decaimiento de pesos de 0.0001. La tasa de aprendizaje inicial fue de 0.0001 para ResNet18 y 0.001 para las capas de clasificación y agregación, utilizando un planificador `CosineAnnealingLR` con horizonte de 15 épocas.

Se utilizó un tamaño de lote de cuatro estudios y acumulación de gradientes durante dos pasos, equivalente a ocho estudios por actualización de parámetros. Para optimizar el consumo de memoria se empleó precisión mixta automática de 16 bits y el formato `channels_last`. Durante el entrenamiento se aplicaron aumentos de datos consistentes en inversión horizontal con probabilidad de 0.5 y desplazamientos de hasta 12 píxeles, manteniendo la misma transformación en todas las posiciones de un estudio.

El número máximo de épocas se estableció en 15, con detención temprana basada en el ROC-AUC del conjunto de validación y una paciencia de cuatro épocas consecutivas sin mejora. El experimento se ejecutó en Kaggle Notebooks utilizando GPU NVIDIA Tesla T4. El tiempo efectivo de entrenamiento fue de aproximadamente 13.7 minutos para MIL y 12.4 minutos para BiGRU, sin incluir la preparación inicial de los datos. Las configuraciones, historiales y *checkpoints* se conservaron como artefactos reproducibles del experimento.

5 Resultados y análisis de resultados

5.1 Características del conjunto de datos original

El conjunto tabular contiene 2019 estudios en `train.csv`: 961 con fractura (`patient_overall` = 1; 47.6 %) y 1058 sin fractura. Solo 235 estudios (11.6 %) cuentan con *bounding boxes* (7 217 anotaciones), todas en estudios positivos (primera entrega del Proyecto 2). Las imágenes son estudios de TC en formato DICOM con entre 69 y 1082 cortes por estudio (mediana 314).

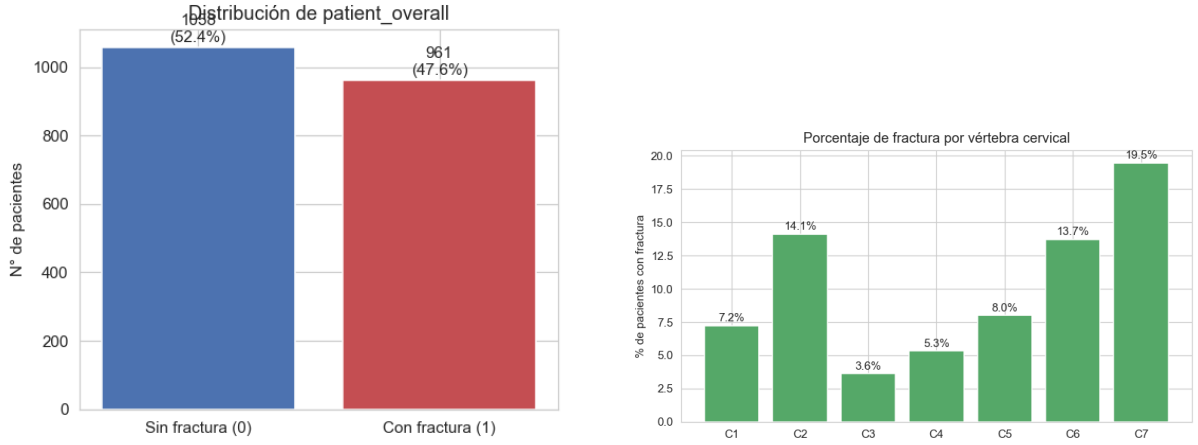


Figura 1: Análisis exploratorio tabular (primera entrega): distribución de la variable objetivo `patient_overall` y frecuencia de fractura por vértebra.

5.2 Limpieza y preprocesamiento

En los CSV no hubo valores nulos ni filas duplicadas, `StudyInstanceUID` es único y `patient_overall` es consistente con la suma de C1–C7, por lo que no se aplicaron correcciones a las etiquetas. En las imágenes, la variabilidad de metadatos no se corrige en los archivos sino en el *pipeline* (sección 5.3): HU calculadas con el `RescaleSlope`/`RescaleIntercept` de cada archivo, ordenamiento por posición z y redimensionado a 224×224.

5.3 Análisis exploratorio de las imágenes DICOM

Fuente y tamaño de muestra. El análisis usa la auditoría del *pipeline* (auditoría del pipeline (artifacts/v2/results/dicom_metadata.csv.gz)): 2019 estudios y 96912 cortes (los 48 centrales de cada estudio). El número de cortes por estudio es el total de archivos del estudio; el resto de metadatos proviene únicamente de esos 48 cortes. El notebook `notebooks/02_eda_imagenes.ipynb` y el script `scripts/eda_metadatos_dicom.py` permiten repetir el análisis leyendo las cabeceras de *todos* los cortes de una muestra estratificada (semilla 42) directamente en Kaggle.

Variable	Media	D. E.	Mín.	Mediana	Máx.
Cortes por estudio	352.452	132.010	69.000	314.000	1082.000
SliceThickness (mm)	0.731	0.185	0.488	0.625	1.000
PixelSpacing (mm)	0.328	0.078	0.190	0.312	0.713
Espaciado z medido (mm)	0.626	0.204	0.312	0.625	2.626

Cuadro 2: Estadística descriptiva por estudio (2019 estudios).

Estadística descriptiva. El grosor de corte toma pocos valores discretos (mediana 0.625 mm, máximo 1 mm, en línea con el criterio de inclusión del conjunto de datos de grosor ≤ 1 mm; Lin et al., 2023), mientras que el tamaño de píxel varía entre 0.19 y 0.713 mm; el número de cortes cubre un rango de más de un orden de magnitud. Tras redimensionar a 224×224, el tamaño físico del píxel resultante varía entre estudios, pues no se remuestrea de forma isotrópica.

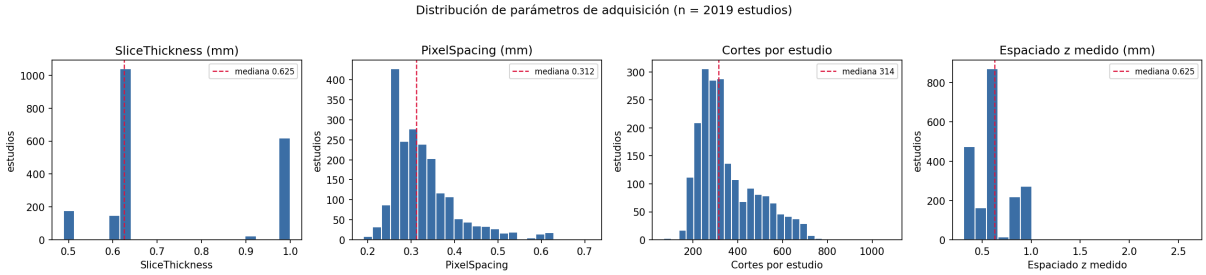


Figura 2: Distribuciones de cortes por estudio, SliceThickness, PixelSpacing y espaciado z medido.

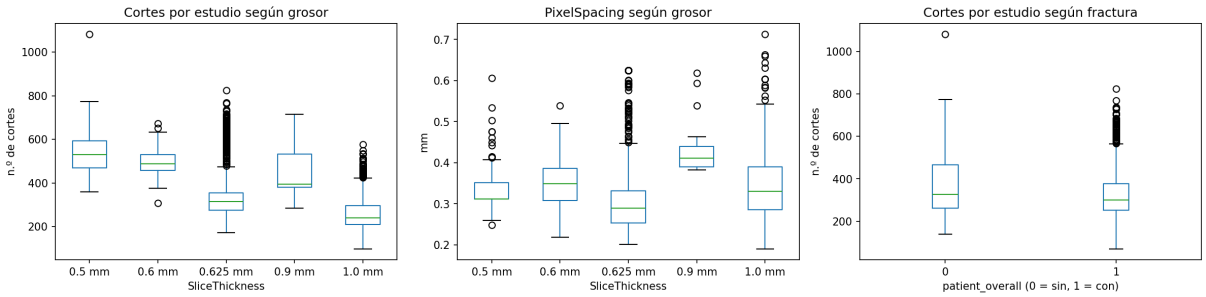


Figura 3: Comparación de parámetros de adquisición según `patient_overall` (descriptiva; sin prueba de hipótesis).

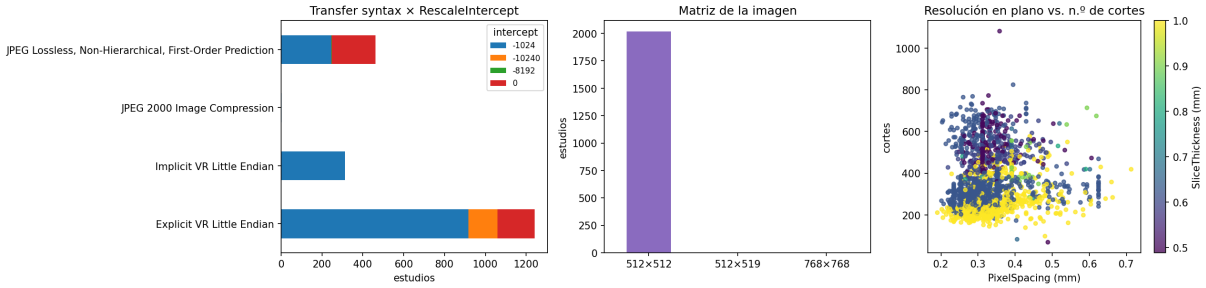


Figura 4: Protocolos de reescalado, sintaxis de transferencia y resolución de matriz.

Comprobación	Estudios	%
Matriz distinta de 512×512	3	0.15
RescaleIntercept $\notin \{-1024, 0\}$ (p. ej. $-8192/-10240$)	144	7.13
RescaleSlope $\neq 1$	141	6.98
Dimensiones de matriz variables dentro del estudio	0	0.00
Slope/intercept variables dentro del estudio	0	0.00
SliceThickness variable dentro del estudio	0	0.00
BitsStored fuera de $\{12, 16\}$	0	0.00
PhotometricInterpretation $\neq$ MONOCHROME2	0	0.00
Atípico (IQR×1.5) en n.° de cortes	27	1.34
Atípico (IQR×1.5) en SliceThickness	0	0.00
Atípico (IQR×1.5) en PixelSpacing	111	5.50
Atípico (IQR×1.5) en espaciado z	2	0.10

Cuadro 3: Comprobaciones de calidad sobre los metadatos. Los umbrales de atípicos usan IQR×1.5.

Valores atípicos y metadatos inconsistentes. Los hallazgos relevantes para el preprocesamiento son: (i) 144 estudios (7.13 %) con `RescaleIntercept` distinto de -1024 y 0: 141 con intercept -10240 y `RescaleSlope` $= 10$, y 3 con intercept -8192; (ii) 3 estudios que no son 512×512; (iii) ningún estudio con dimensiones, grosor o reescalado variables *dentro* del estudio, ni fotometría distinta de MONOCHROME2; (iv) 111 estudios con `PixelSpacing` atípico y 27 con número de cortes atípico. Que las HU resultantes de los estudios con reescalado atípico sean plausibles se comprueba con píxeles reales y no con metadatos (véase más abajo).

Orden de los cortes y auditoría del *pipeline*. El sentido de z respecto al número de instancia no es constante: 1821 estudios son decrecientes, 197 crecientes y 1 mixto; 1 estudio no es monótono. Los estudios con espaciado z irregular o no monótono son …20756, …8362, …8693 (identificados por los últimos dígitos de su UID). Esto justifica ordenar por `ImagePositionPatient[2]` y no por número de instancia. El sentido creciente es más frecuente en estudios positivos (12.6 % frente a 7.3 % en negativos; χ^2, $p = 8.4e-05$); es una asociación descriptiva que podría reflejar diferencias de protocolo o institución, que los metadatos disponibles no permiten confirmar. El preprocesamiento de los 2019 estudios terminó con 0 fallos; el tiempo por estudio fue de 2.52 s en promedio (mediana 2.19 s, máximo 5.2 s) y los estudios comprimidos con JPEG Lossless tardaron aproximadamente el doble que los no comprimidos (mediana 4.07 s frente a 2.11 s con Explicit VR Little Endian).

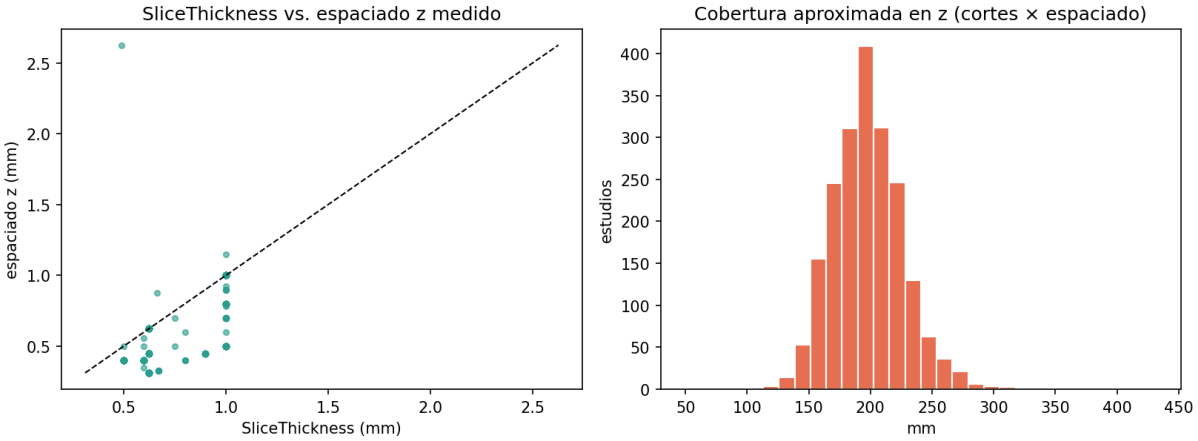


Figura 5: Consistencia del eje z entre estudios.

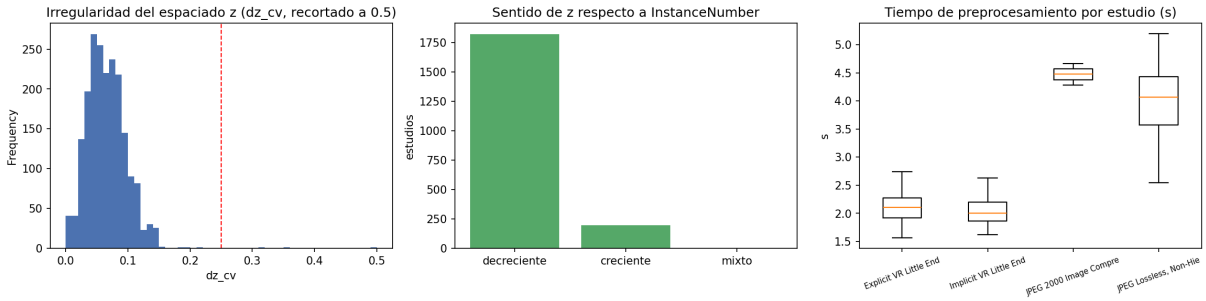


Figura 6: Auditoría del *pipeline*: irregularidad del espaciado z, sentido de z y tiempo de preprocesamiento por sintaxis de transferencia.

Ejemplos reales antes y después del preprocesamiento. Las figuras siguientes provienen del *pipeline* de entrenamiento (`artifacts/v2/results/figures/`) y muestran el corte en HU crudo, el histograma con la ventana ósea y el resultado final.

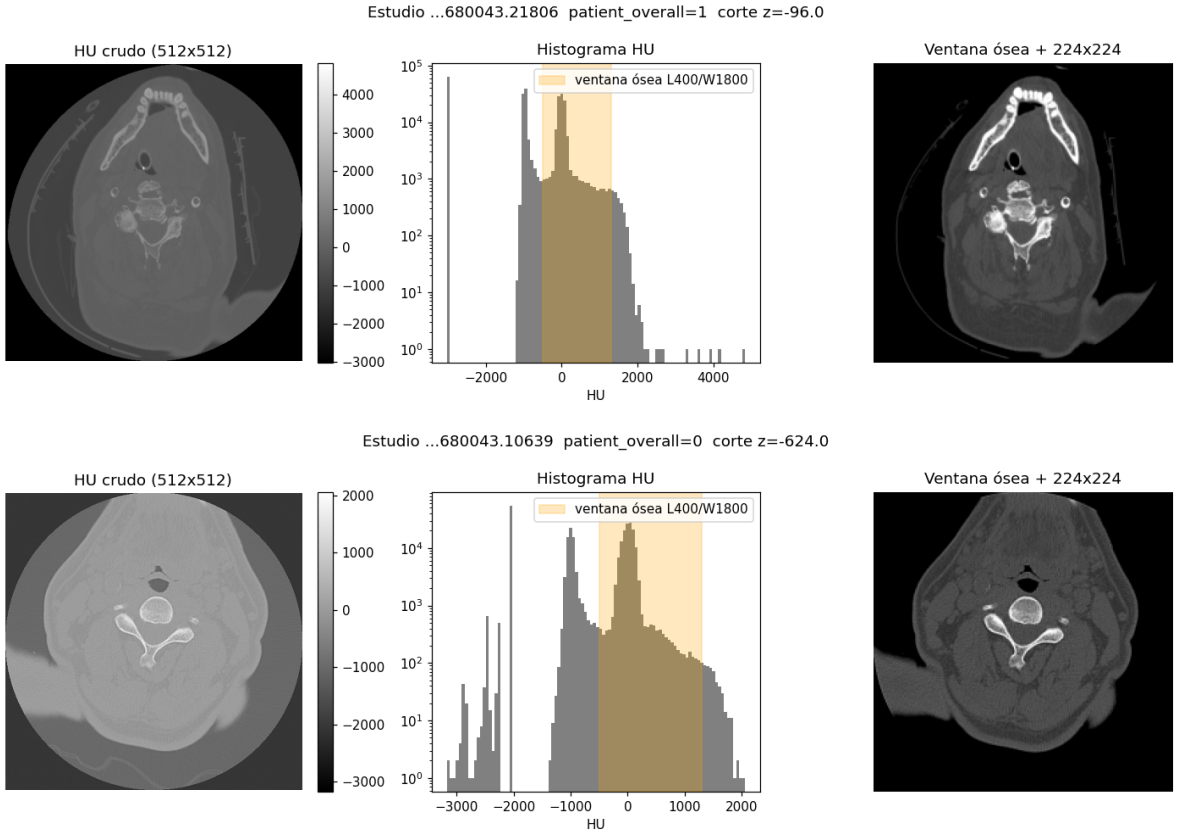


Figura 7: Antes y después del preprocesamiento en un estudio positivo (arriba) y uno negativo (abajo).

PENDIENTE — Intensidades (HU) por grupo de reescalado y diferencias de adquisición

Histogramas de HU del corte central de una submuestra, con todos los estudios de reescalado atípico y estudios aleatorios, y la comparación antes/después sobre ellos (sección 5 del notebook 02).

Fuente esperada: Ejecución de `notebooks/02_eda_imagenes.ipynb` en Kaggle con la competencia como entrada (produce `intensidades_corte_central.csv` y las figuras 05

y 06).

Limitaciones del EDA de imágenes.

- Solo se dispone de las cabeceras de 48 cortes centrales por estudio; no se pueden detectar huecos en z ni cabeceras atípicas fuera de esos cortes.
- El espaciado z medido es la distancia entre dos cortes consecutivos *muestreados*, no una mediana del estudio. Por ello la comparación grosor vs. espaciado z (879 estudios, 43.54 %) no es concluyente y se excluye de la tabla de calidad hasta confirmarla con cabeceras completas.
- Las comprobaciones sobre cabeceras no sustituyen una revisión clínica de la calidad de imagen ni miden artefactos (metal, movimiento).
- La comparación por `patient_overall` es descriptiva, sin control de confusores de protocolo.

5.4 Ajuste de parámetros

El procedimiento experimental distinguió entre los hiperparámetros definidos previamente al entrenamiento y las decisiones realizadas a partir del desempeño observado en el conjunto de validación. No se implementó una búsqueda sistemática de hiperparámetros mediante métodos como *grid search*, *random search* u optimización bayesiana. En su lugar, se utilizó una configuración inicial fija y comparable para ambas arquitecturas, seleccionando posteriormente la mejor época y el umbral operativo de clasificación mediante los resultados de validación.

Los hiperparámetros compartidos, entre ellos las tasas de aprendizaje, el tamaño de lote, el decaimiento de pesos, la probabilidad de *dropout*, la configuración del preprocesamiento y los aumentos de datos, permanecieron constantes durante la comparación. Las diferencias arquitectónicas se limitaron principalmente al mecanismo de agregación: el promedio de los tres logits más altos en MIL y una GRU bidireccional de 128 unidades por dirección en BiGRU. El peso de la clase positiva, aproximadamente 1.1008, se calculó directamente a partir de la distribución de las etiquetas del conjunto de entrenamiento y no fue seleccionado mediante optimización experimental.

La primera decisión basada en validación fue la selección de la época óptima. Al finalizar cada época se calculó el ROC-AUC sobre los 323 estudios de validación y se conservó el *checkpoint* correspondiente cuando este indicador mejoraba. Se aplicó detención temprana después de cuatro épocas consecutivas sin incremento del ROC-AUC, con el propósito de limitar el sobreajuste y evitar entrenamiento adicional sin mejoras observadas.

En ResNet18 + MIL, el entrenamiento finalizó después de 10 épocas y el mejor *checkpoint* correspondió a la época 6, con un ROC-AUC de validación de 0.6870. En ResNet18 + BiGRU, el entrenamiento finalizó después de 9 épocas y el mejor *checkpoint* se obtuvo en la época 5, con un ROC-AUC de validación de 0.7255. Los historiales muestran que la pérdida de entrenamiento continuó disminuyendo mientras la pérdida de validación aumentaba en las épocas posteriores, lo cual constituye una señal de sobreajuste. Por tanto, la selección del *checkpoint* permitió conservar los estados con mejor capacidad discriminativa observada en validación, en lugar de utilizar los parámetros de la última época.

La segunda decisión fue la determinación del umbral de clasificación. Una vez recuperado el mejor *checkpoint* de cada modelo, se calculó la curva ROC sobre el conjunto de validación y se seleccionó el umbral que maximizaba el índice de Youden, definido como la suma de sensibilidad y especificidad menos uno. Este procedimiento produjo un umbral de 0.54952 para MIL y 0.54813 para BiGRU. Ambos umbrales se mantuvieron sin modificaciones durante la evaluación sobre

los 404 estudios de prueba, evitando utilizar las etiquetas de prueba para ajustar la regla de decisión.

La elección del umbral afecta directamente las métricas dependientes de una clasificación binaria, como sensibilidad, especificidad, precisión, F1-score y exactitud. En cambio, el ROC-AUC evalúa la capacidad discriminativa considerando múltiples umbrales y no cambia por seleccionar un punto de operación específico. Adicionalmente, se calcularon resultados utilizando un umbral de referencia de 0.5, exclusivamente con fines comparativos.

La ausencia de una búsqueda exhaustiva de hiperparámetros constituye una limitación metodológica del experimento, ya que no permite asegurar que las configuraciones seleccionadas sean óptimas para cada arquitectura. Asimismo, los historiales de entrenamiento muestran variabilidad en el ROC-AUC de validación, particularmente en MIL, cuyo valor máximo de 0.687 disminuyó a aproximadamente 0.638 en el conjunto de prueba. Estos resultados sugieren que la selección de parámetros y la estimación de generalización podrían beneficiarse de validación cruzada, experimentos con múltiples semillas y una búsqueda controlada de configuraciones en investigaciones posteriores.

Finalmente, la ampliación del diseño inicial desde una muestra piloto de 160 estudios y 24 cortes hacia el procesamiento de 2,019 estudios con 48 posiciones 2.5D constituyó una decisión metodológica previa a los entrenamientos definitivos, no un ajuste seleccionado mediante comparación de métricas. Por tanto, no se atribuyen mejoras cuantitativas a dicho cambio, puesto que no se dispone de resultados experimentales equivalentes para la configuración piloto.

5.5 Comparación de algoritmos

Pruebas estadísticas pareadas

La comparación entre ResNet18 + MIL y ResNet18 + BiGRU se realizó sobre el mismo conjunto de prueba ($n = 404$ estudios) utilizando pruebas estadísticas pareadas para determinar si las diferencias en rendimiento son significativas.

Cuadro 4: Pruebas estadísticas pareadas entre modelos ($n = 404$).

Prueba	**Resultado**	**Interpret**
DeLong (1988)	$\Delta\text{AUC} = +0.099$, $z = 4.09$, $p = 4.3 \times 10^{-5}$	Diferencia
Bootstrap pareado (2000 remuestreos)	IC95% ΔAUC: [+0.048, +0.147]; 0% de remuestreos ≤ 0	BiGRU co
McNemar exacto (umbral val)	66 vs 48 aciertos exclusivos, $p = 0.11$	Dirección
Correlación Spearman	$\rho = 0.60$	Acuerdo r

En el conjunto de validación ($n = 323$), la dirección de la diferencia es la misma pero no alcanza significación estadística (DeLong $p = 0.115$; bootstrap IC95% $[-0.010, +0.086]$).

Selección del modelo: ResNet18 + BiGRU

El criterio de selección, fijado antes del entrenamiento, fue el ROC-AUC de prueba y el equilibrio entre sensibilidad y especificidad. La selección de ResNet18 + BiGRU como modelo recomendado se justifica en cinco aspectos:

1. **AUC superior y estadísticamente significativo:** 0.737 vs 0.638 (DeLong $p < 0.001$).
2. **Mejor sensibilidad:** 0.641 vs 0.365; detecta 53 fracturas reales más que MIL (123 vs 70 TP).
3. **Mejor F1-score:** 0.632 vs 0.465; balance más equilibrado entre precisión y sensibilidad.

4. **Estabilidad entre validación y prueba:** AUC estable (0.725 → 0.737), mientras que MIL cayó (0.687 → 0.638).
5. **Inferencia más rápida:** 23.8 vs 28.0 ms/estudio.

Es importante notar que la prueba de McNemar no alcanza significación en predicciones binarias ($p = 0.11$), lo que indica que la diferencia es más clara en probabilidades continuas (evaluadas por DeLong) que en clasificaciones binarias con un umbral fijo. Con los umbrales seleccionados en validación, MIL opera con baja sensibilidad (0.365) y BiGRU con un punto operativo más equilibrado (sensibilidad 0.641, especificidad 0.651).

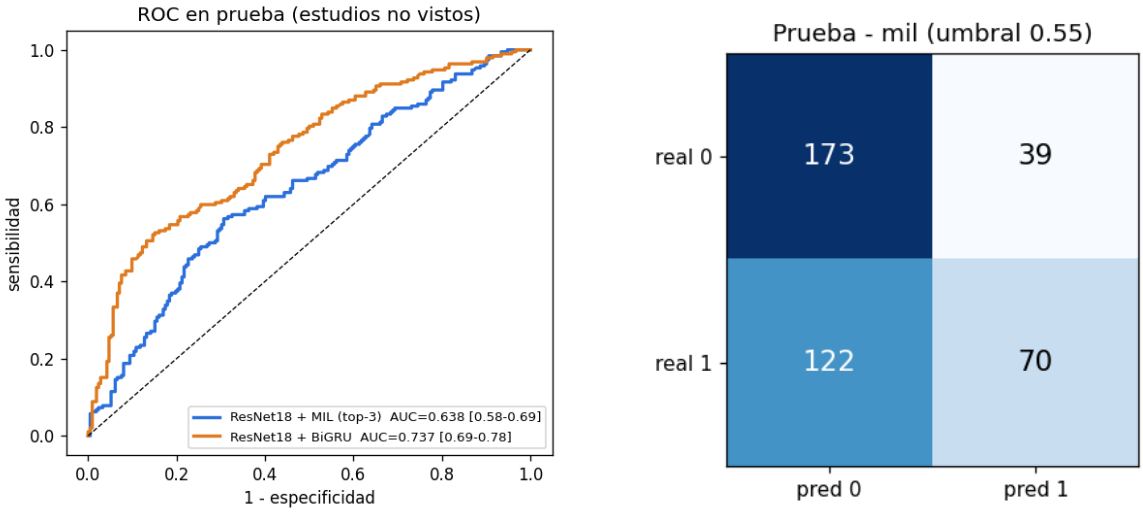


Figura 8: Curvas ROC comparativas (izquierda) y matriz de confusión de MIL (derecha) en el conjunto de prueba.

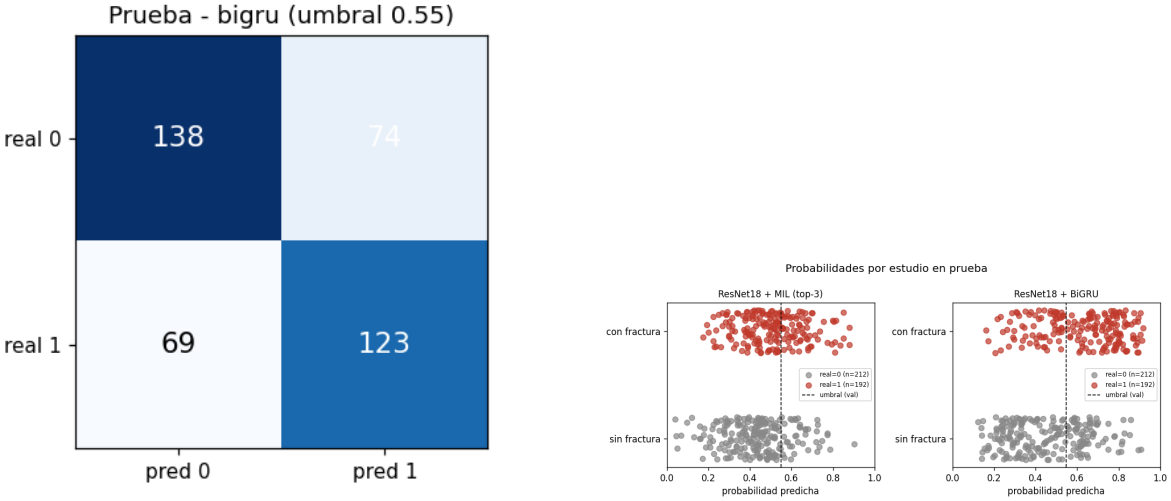


Figura 9: Matriz de confusión de BiGRU (izquierda) y distribución de probabilidades predichas por clase real (derecha). La línea vertical indica el umbral seleccionado en validación.

5.6 Aplicación desarrollada

Se desarrolló una aplicación web interactiva con Streamlit que integra la exploración de datos, el preprocesamiento, la predicción sobre estudios nuevos y la comparación de los dos modelos entrenados (A: ResNet18 + MIL; B: ResNet18 + BiGRU). Se ejecuta con `streamlit run`

`experimento_dl/app_streamlit.py`; su documentación está en `docs/app/APP_STREAMLIT.md` y la demostración de la integración en `notebooks/04_integracion_app.ipynb`.

Las tecnologías elegidas y su justificación se resumen en el cuadro 5.

Componente	Justificación
Streamlit	Interfaz web en Python puro, sin desarrollo *front-end* separado; permite reutilizar directamente los módulos del *pipeline* y cachear modelos y lecturas DICOM.
Plotly	Gráficas interactivas (zoom, *hover*, selección de series) para explorar métricas y distribuciones; con un interruptor se sustituyen por las figuras estáticas PNG del entrenamiento.
pydicom, pylibjpeg/GDCM	Lectura de los mismos DICOM que en entrenamiento, incluidos los comprimidos con JPEG Lossless.
PyTorch	Carga de los checkpoints en modo seguro (`weights_only`) e inferencia en CPU o GPU (Paszke et al., 2019).
`inference.py` y `metrics_eval.py`	Preprocesamiento e inferencia del *pipeline* de entrenamiento, y métricas e intervalos bootstrap del módulo de evaluación independiente; la aplicación no reimplementa ninguno de los dos.

Cuadro 5: Tecnologías de la aplicación y justificación de su elección.

Coherencia con el entrenamiento. La aplicación no reimplementa el preprocesamiento ni las arquitecturas: usa `inference.py`, que reconstruye la configuración guardada con cada checkpoint (48 posiciones 2.5D, ventana ósea $L = 400/W = 1800$, 224×224, orden por `ImagePositionPatient[2]`). En el notebook de integración se comprobó que el tensor que recibe el modelo en la aplicación coincide en forma ($48 \times 3 \times 224 \times 224$), tipo y parámetros con el de entrenamiento, y que no depende del orden en que se suban los archivos. Antes de cargar un checkpoint se verifica su huella SHA-256 frente a `artifacts/v2/MANIFEST.json`.

Funcionalidades. La aplicación se organiza en ocho pestañas: (1) exploración de `train.csv` y de los metadatos DICOM (figura 10); (2) pasos y ejemplos del preprocesamiento; (3) visor DICOM, que muestra cada corte en HU crudas y tras la ventana ósea, su histograma, los metadatos y el tensor de entrada del modelo (figura 11); (4) predicción; (5) métricas por modelo y conjunto; (6) comparación de modelos; (7) estado de los artefactos, y (8) limitaciones. Un panel lateral permite alternar entre gráficas interactivas y estáticas, y mostrar u ocultar cada tipo de gráfica.

Predicción de nuevas entradas. El usuario sube los archivos DICOM de un estudio, o selecciona uno o varios estudios locales, y elige el Modelo A, el B o ambos. Cada resultado muestra la probabilidad, la clase según el umbral fijado en validación (índice de Youden; Youden, 1950), los avisos de calidad de la entrada (archivos ilegibles, estudios mezclados, menos cortes que posiciones del modelo o ausencia de `RescaleSlope`) y un descargo explícito: es una clasificación global por estudio, sin localización y sin validación clínica. Si se ejecutan ambos modelos, la aplicación indica si coinciden, la diferencia de probabilidades y el percentil de cada probabilidad en la distribución del conjunto de prueba, por clase real. Si el estudio pertenece a las particiones del experimento, compara la probabilidad obtenida con la registrada en la evaluación, lo que verifica que el despliegue reproduce el modelo evaluado; si pertenece a entrenamiento, advierte que no es una evaluación independiente. La etiqueta real, cuando se conoce, se muestra aparte y rotulada como tal. Mientras los checkpoints no están disponibles, la pestaña muestra el estado PENDIENTE y no genera probabilidades (figura 12); las predicciones del conjunto de prueba ya calculadas en la evaluación se pueden consultar estudio por estudio.

Comparación interactiva de modelos. El usuario elige conjuntos y métricas; la aplicación presenta barras agrupadas, la diferencia B − A, las pruebas pareadas (DeLong, bootstrap y McNemar), las curvas ROC con el punto de operación, la distribución de probabilidades por clase y la dispersión de las probabilidades de ambos modelos por estudio (figura 13). Un control de umbral recalcula las métricas sobre las predicciones de prueba, con intervalos de confianza bootstrap al 95 % (Efron and Tibshirani, 1993); esta exploración es descriptiva, pues los umbrales oficiales se fijaron en validación. Todos los valores provienen de los artefactos reales del entrenamiento (`artifacts/v2/`); si falta alguno, se muestra PENDIENTE y no se generan valores sustitutos.

Pruebas. La aplicación se validó con 25 pruebas automáticas propias: consistencia de las métricas con las predicciones, entradas inválidas (sin archivos, no DICOM, vacíos, estudios mezclados), rechazo de checkpoints ausentes o alterados, forma de la entrada, flujo completo de predicción y comparación en la interfaz, e inferencia por lotes. Algunas pruebas de interfaz usan checkpoints con pesos aleatorios únicamente para ejercitar el código; con ellos, la verificación de reproducibilidad señala correctamente que no coinciden con la evaluación. Además, se revisaron las ocho pestañas en el navegador sin errores.

Validación con los checkpoints reales. Los checkpoints de ambos modelos se verificaron contra `artifacts/v2/MANIFEST.json` (tamaño y SHA-256 idénticos) y se cargan en modo seguro con el umbral y la configuración de preprocesamiento publicados. Para comprobar que la aplicación reproduce el modelo evaluado, se descargaron desde Kaggle los DICOM completos de dos estudios de la partición de *prueba* (uno sin fractura y uno con fractura) y se procesaron con la aplicación en CPU, desde los archivos crudos. Las cuatro probabilidades coinciden con las registradas en la evaluación, con una diferencia máxima de 6.3×10^{-4} (tolerancia 10^{-3}; la evaluación se ejecutó en GPU con precisión mixta), y las clases predichas son las mismas (cuadro 6). El tiempo de inferencia, preprocesamiento incluido, fue de unos 0.9 s por estudio y modelo. Esta comprobación es técnica: confirma la fidelidad del despliegue, no constituye una nueva evaluación del desempeño.

Estudio (UID)	Modelo	p app	p evaluación	$\lvert\Delta\rvert$	Predicción	Etiqueta real
`...3680043.8744`	A (MIL)	0.4910	0.4908	1.7×10^{-4}	sin fractura	sin fractura
	B (BiGRU)	0.1673	0.1674	2.8×10^{-5}	sin fractura	
`...3680043.9926`	A (MIL)	0.5106	0.5099	6.3×10^{-4}	sin fractura	con fractura
	B (BiGRU)	0.8217	0.8219	1.8×10^{-4}	fractura	

Cuadro 6: Reproducción de la evaluación desde DICOM crudo en la aplicación (CPU). Umbrales de validación: 0.550 (A) y 0.548 (B). Fuente: `docs/app/validacion_inferencia.{csv,json}`.

En el estudio con fractura, el Modelo A queda por debajo de su umbral (falso negativo) y el Modelo B lo clasifica correctamente; la aplicación señala esa discrepancia (figura 12). Es un caso ilustrativo y coherente con la mayor sensibilidad de B en prueba, no una evidencia adicional de su superioridad.

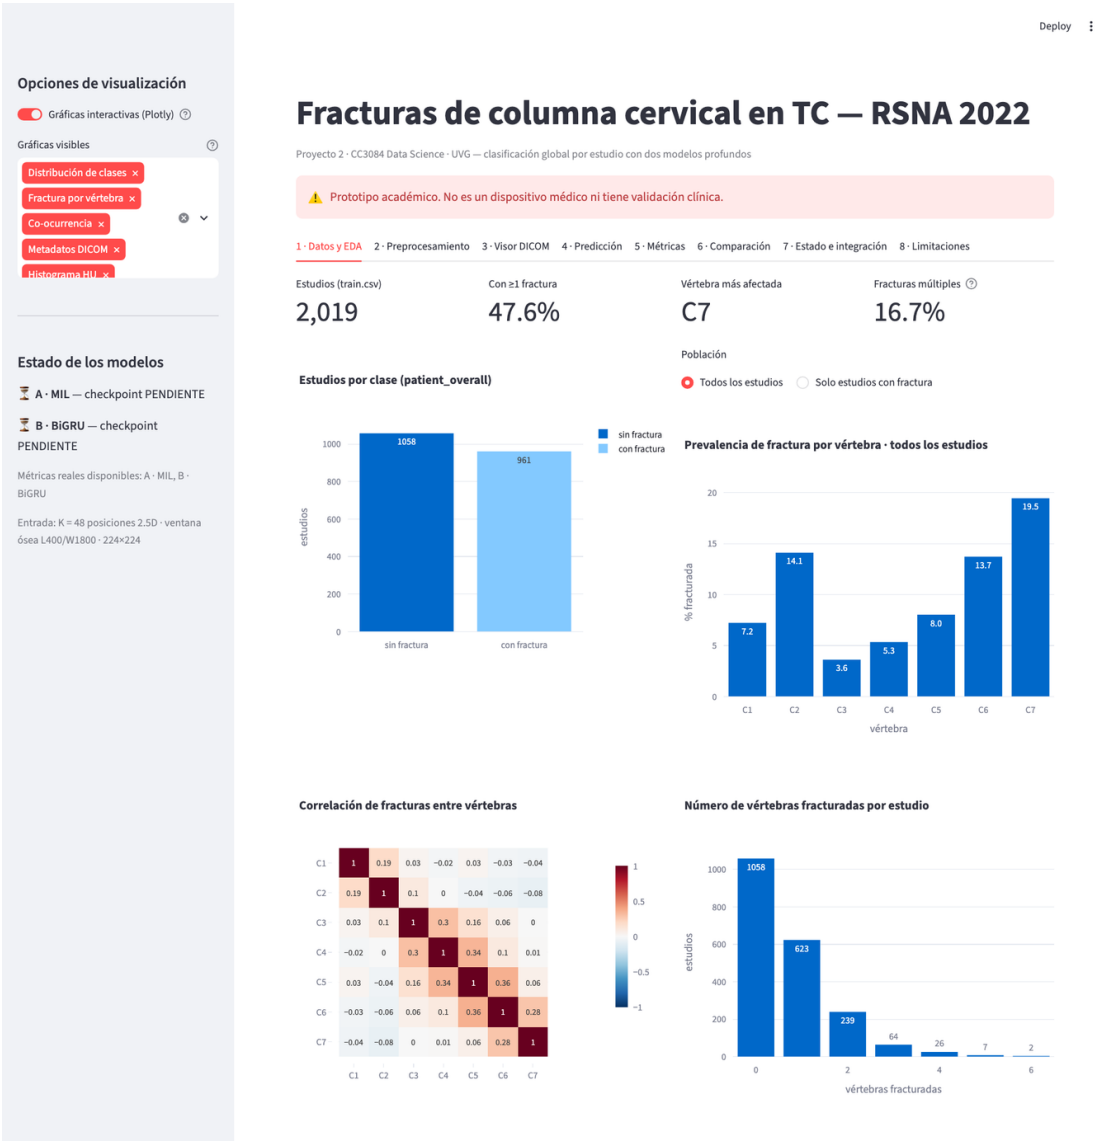


Figura 10: Aplicación, pestaña 1: exploración interactiva de `train.csv`, particiones y metadatos DICOM.

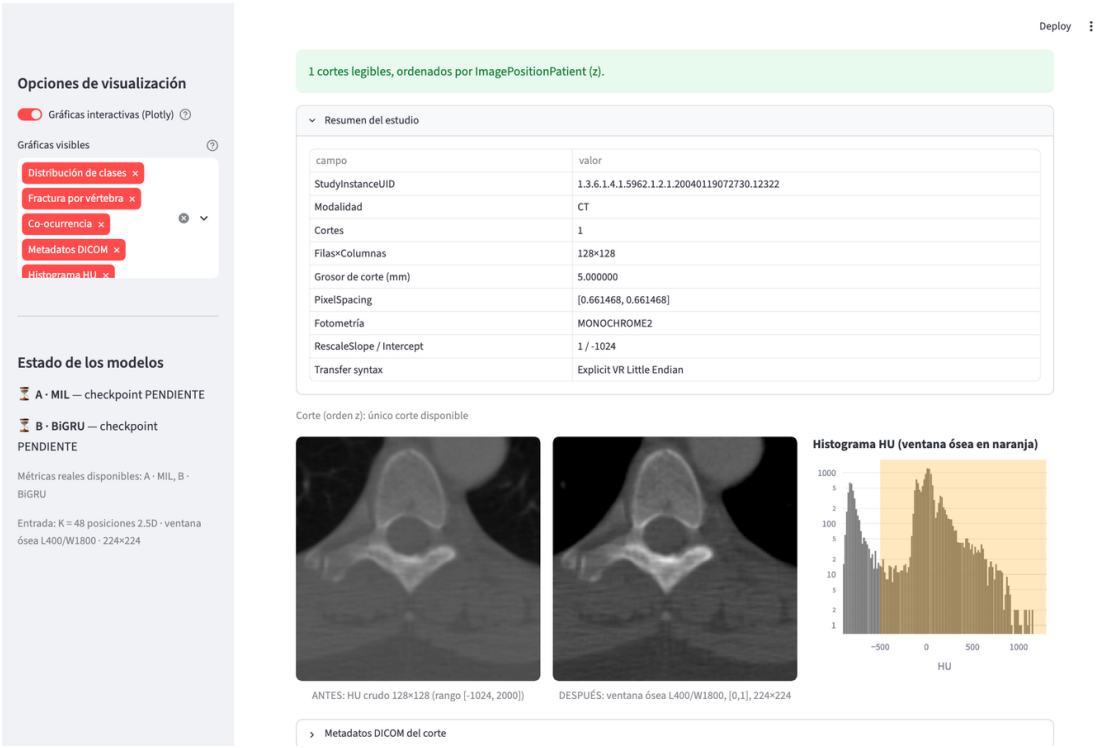


Figura 11: Aplicación, pestaña 3: visor DICOM con el corte en HU crudas, tras la ventana ósea y su histograma (corte de TC de prueba de `pydicom`).

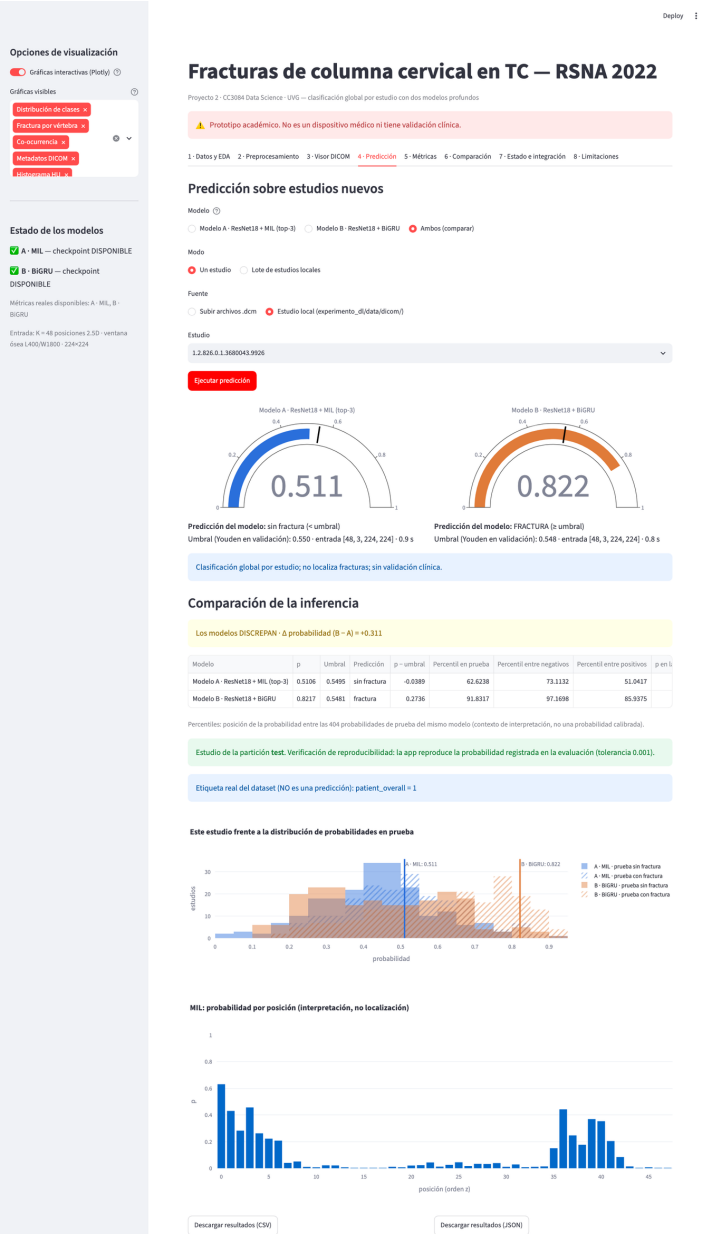


Figura 12: Aplicación, pestaña 4: predicción real con ambos modelos sobre un estudio de prueba con fractura (`...3680043.9926`): medidores con umbral, discrepancia entre modelos, verificación de reproducibilidad, etiqueta real rotulada aparte, posición en la distribución de prueba y probabilidades por posición del Modelo A.

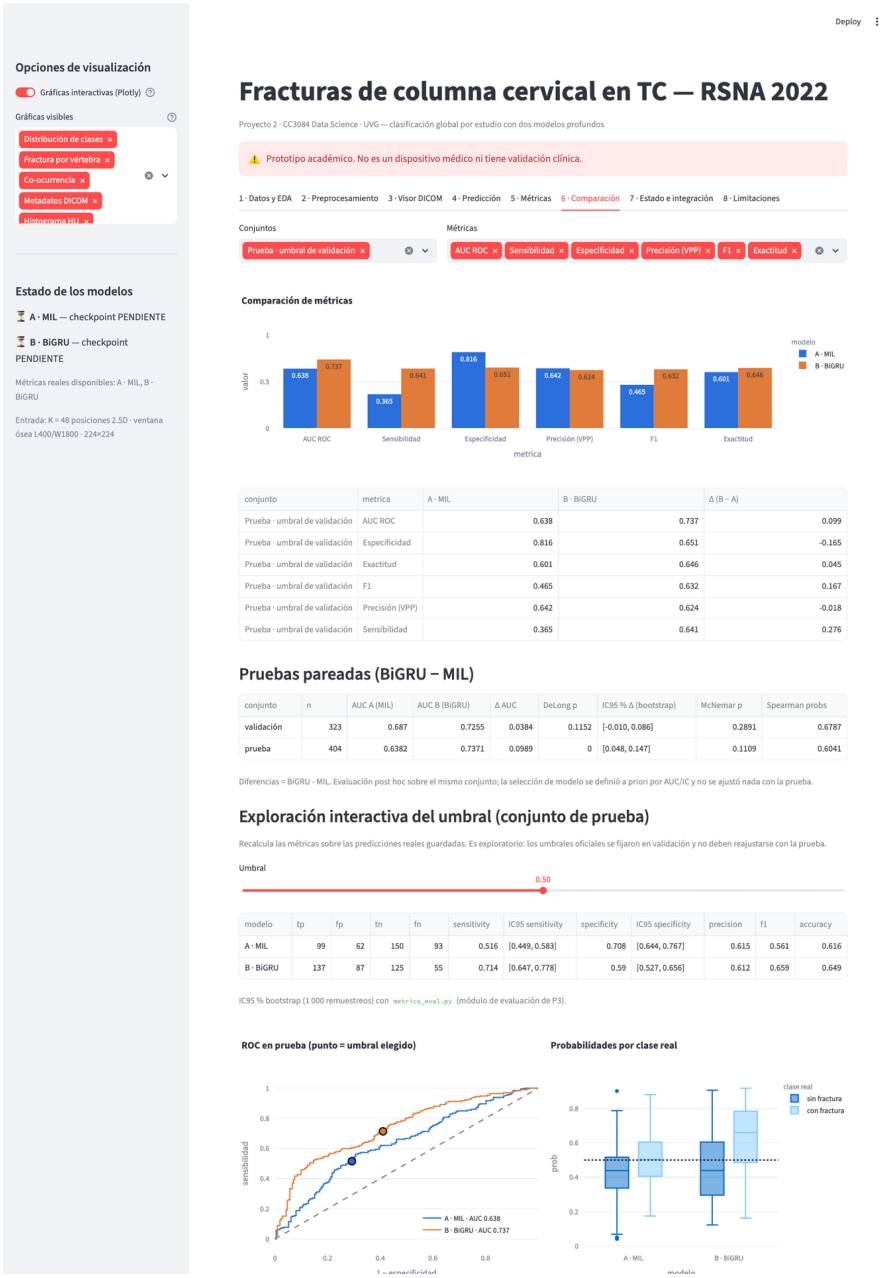


Figura 13: Aplicación, pestaña 6: comparación interactiva de los modelos A y B en el conjunto de prueba.

6 Conclusiones

El experimento completó exitosamente el pipeline de clasificación de fracturas cervicales en TC desde el preprocesamiento DICOM hasta la evaluación comparativa de modelos, utilizando los 2019 estudios completos del dataset RSNA 2022 y entrenamiento en GPU Tesla T4 mediante Kaggle Notebooks.

Cumplimiento de objetivos

1. **Construir muestra estratificada sin fuga:** Se procesaron 2019 estudios con particiones disjuntas por `StudyInstanceUID` (1292 entrenamiento, 323 validación, 404 prueba), estratificadas por `patient_overall` con semilla 42. Las verificaciones independientes confirman

que no hay fuga de datos entre particiones.

2. **Implementar preprocesamiento DICOM reproducible:** El pipeline convierte valores de píxel a unidades Hounsfield usando `RescaleSlope`/`RescaleIntercept` por archivo, aplica ventana ósea (nivel 400, ancho 1800 HU), redimensiona a 224×224 y ordena por `ImagePositionPatient[2]`. La auditoría de 96 912 cortes centrales documenta la variabilidad de metadatos (múltiples protocolos de reescalado, grosores de 0.49–1.0 mm, espaciado z de 0.31–2.63 mm).
3. **Entrenar y evaluar dos arquitecturas:** ResNet18 + MIL (agregación top-3) y ResNet18 + BiGRU (secuencia ordenada por z) fueron entrenados con los mismos hiperparámetros, evaluados con métricas apropiadas (sensibilidad, especificidad, precisión, F1, exactitud, ROC-AUC) e intervalos de confianza del 95% mediante bootstrap.
4. **Seleccionar modelo con incertidumbre cuantificada:** BiGRU fue seleccionado como modelo recomendado con base en AUC superior (0.737 vs 0.638, $\Delta = +0.099$, prueba de DeLong $p < 0.001$) y mejor equilibrio sensibilidad/especificidad. El bootstrap pareado confirma que en el 100% de los remuestreos BiGRU supera a MIL.
5. **Desarrollar aplicación con inferencia:** La aplicación Streamlit permite cargar estudios DICOM, aplicar el mismo preprocesamiento que en entrenamiento y obtener predicciones con ambos modelos o compararlos interactivamente.

Hallazgos principales

1. **BiGRU supera estadísticamente a MIL** (ΔAUC $= +0.099$, $p < 0.001$ según prueba de DeLong). El bootstrap pareado confirma que en el 100% de los remuestreos BiGRU tuvo mejor AUC, con IC95% de la diferencia [+0.048, +0.147] que no incluye el cero.
2. **BiGRU ofrece mejor sensibilidad** (0.641 vs 0.365), detectando 53 fracturas reales más que MIL (123 vs 70 TP). Esto es clínicamente relevante: en *screening* médico, los falsos negativos son más costosos que los falsos positivos.
3. **Ambos modelos tienen desempeño moderado.** El mejor AUC alcanzado (0.737) está lejos del umbral de utilidad clínica (>0.90). La especificidad de BiGRU (0.651) genera 74 falsos positivos, lo que limitaría su uso como herramienta autónoma.
4. **El modelado secuencial captura contexto anatómico.** BiGRU procesa los 48 cortes ordenados por z, permitiendo que la red aprenda relaciones espaciales entre vértebras adyacentes. MIL trata cada corte independientemente y solo promedia los 3 logits más altos, perdiendo información contextual.

Limitaciones críticas

- **Una sola partición y semilla:** Los resultados pueden no generalizar a otras divisiones de datos. Se requiere validación cruzada k-fold para estimar varianza.
- **Muestreo de 48 cortes** de estudios con 69–1082 cortes totales: muchas fracturas pueden no estar en los cortes seleccionados, introduciendo ruido de etiqueta.
- **Clasificador global:** No localiza la fractura ni identifica la vértebra afectada.
- **Sin validación clínica ni externa:** Las métricas no son comparables con las de la competencia (que usa métrica ponderada por vértebra en test oculto).
- **Prevalencia del 47.5%** en el conjunto de prueba es artificialmente alta comparada con la población clínica real (∼5–10% en pacientes de trauma), lo que infla métricas como precisión.

Recomendaciones

1. No desplegar en producción clínica sin validación prospectiva con radiólogos y datos de instituciones independientes.

2. Incrementar el muestreo de cortes (ej. 96 o 128 posiciones) para reducir el riesgo de no muestrear la fractura.
3. Implementar validación cruzada 5-fold para obtener estimaciones más robustas del desempeño y su varianza.
4. Explorar arquitecturas 3D (ej. 3D ResNet) que procesen el volumen completo sin necesidad de muestreo de cortes.
5. Ajustar el umbral de decisión según el costo clínico de falsos positivos vs falsos negativos, en consulta con radiólogos.

Conclusiones del EDA de imágenes (P2)

La heterogeneidad de los metadatos DICOM es real y medible: reescalado atípico en 7.13 % de los estudios, tamaños de píxel entre 0.19 y 0.713 mm, sentido de z variable y compresión distinta entre estudios. Las decisiones del *pipeline* (HU por archivo, orden por z, ventana ósea) responden a esa heterogeneidad. Quedan abiertas dos verificaciones que requieren píxeles: la plausibilidad de las HU en los estudios con reescalado atípico y el análisis de intensidades por grupo de adquisición (ver el recuadro de pendientes en la sección 5.3).

Limitaciones generales

Una sola partición y una sola semilla; 48 posiciones por estudio de cientos de cortes (la fractura puede no estar muestreada); clasificador global que no localiza la fractura; sin remuestreo isotrópico; sin validación clínica ni externa, por lo que las métricas no son comparables con las de la competencia.

Referencias

Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., and Bengio, Y. (2014). Learning phrase representations using RNN encoder–decoder for statistical machine translation. In *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1724–1734.

Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., and Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. In *2009 IEEE Conference on Computer Vision and Pattern Recognition*, pages 248–255.

Efron, B. and Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall.

Hanley, J. A. and McNeil, B. J. (1982). The meaning and use of the area under a receiver operating characteristic (ROC) curve. *Radiology*, 143(1):29–36.

He, K., Zhang, X., Ren, S., and Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 770–778.

Hoffman, J. R., Mower, W. R., Wolfson, A. B., Todd, K. H., and Zucker, M. I. (2000). Validity of a set of clinical criteria to rule out injury to the cervical spine in patients with blunt trauma. *New England Journal of Medicine*, 343(2):94–99.

Ilse, M., Tomczak, J., and Welling, M. (2018). Attention-based deep multiple instance learning. In *Proceedings of the 35th International Conference on Machine Learning*, pages 2127–2136. PMLR.

Lin, H. M., Colak, E., Richards, T., Kitamura, F. C., Prevedello, L. M., Talbott, J., Ball, R. L., Gumeler, E., Yeom, K. W., Hamghalam, M., Simpson, A., Strika, J., Bulja, D., Angkurawaranon, S., Pérez-Lara, A., Gómez-Alonso, M., Ortiz Jiménez, J., Peoples, J., Law, M., Dogan, H., Altinmakas, E., Youssef, A., Mahfouz, Y., Kalpathy-Cramer, J., and Flanders, A. E. (2023). The RSNA cervical spine fracture CT dataset. *Radiology: Artificial Intelligence*, 5(5):e230034.

Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., et al. (2019). PyTorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems 32*, pages 8024–8035.

Radiological Society of North America (2022). RSNA 2022 cervical spine fracture detection [competencia].

Stiell, I. G., Wells, G. A., Vandemheen, K. L., Clement, C. M., Lesiuk, H., De Maio, V. J., et al. (2001). The Canadian C-spine rule for radiography in alert and stable trauma patients. *JAMA*, 286(15):1841–1848.

Youden, W. J. (1950). Index for rating diagnostic tests. *Cancer*, 3(1):32–35.

A Estado de integración del informe (uso interno; eliminar antes de entregar)

Sección	Responsable	Estado
Introducción, marco teórico (TC, DL, evaluación)	P2 (integración)	Redactado a partir del borrador del equipo
Anatomía y fracturas (marco teórico médico)	Revisión bibliográfica	Pendiente de integrar desde el .docx
Datos, particiones, preprocesamiento	P2 / GPU	Redactado con cifras v2 (verificar con GPU)
Metodología de entrenamiento y ajuste	Responsable GPU	Pendiente
EDA de imágenes (metadatos, orden z, tiempos)	P2	Con cifras reales de la auditoría
EDA de imágenes (intensidades HU, antes/después propios)	P2	Pendiente de ejecución en Kaggle
Comparación de modelos y conclusiones	P3	Pendiente
Aplicación y capturas	P1	Completo (inferencia real validada en 2 estudios de prueba)
Resumen	Todos	Pendiente (al cierre)

Cuadro 7: Matriz de integración. Los recuadros amarillos del texto son los espacios reservados.