Clasificación global de fracturas cervicales en tomografía computarizada a partir de una muestra de RSNA 2022

Pablo Andrés Cabrera (231156) Hansel André López (19026)
Pablo José Méndez (23975) María José Yee (231193)

Universidad del Valle de Guatemala — CC3084 Data Science
Guatemala, octubre de 2026

Resumen

PENDIENTE — Resumen

El resumen se redacta al cierre, cuando existan los resultados finales de entrenamiento, la comparación de modelos y las conclusiones.

Fuente esperada: Resultados de la responsable GPU y de la comparación (P3).

Índice general

1 Introducción **3**
1.1 Problema científico . . . 3

2 Objetivos **3**
2.1 Objetivo general . . . 3
2.2 Objetivos específicos . . . 3

3 Marco teórico **3**
3.1 Tomografía computarizada, DICOM y unidades Hounsfield . . . 3
3.2 Procesamiento de imágenes médicas . . . 4
3.3 Análisis de las imágenes desde el punto de vista médico . . . 4
3.4 Algoritmos de aprendizaje profundo . . . 4
3.5 Evaluación . . . 4

4 Metodología **4**
4.1 Pasos seguidos por el grupo . . . 4
4.2 Datos y particiones . . . 5
4.3 Preprocesamiento . . . 5
4.4 Herramientas y recursos de cómputo . . . 5
4.5 Selección de algoritmos, arquitecturas y configuración de entrenamiento . . . 5

5 Resultados y análisis de resultados **6**
5.1 Características del conjunto de datos original 6
5.2 Limpieza y preprocesamiento 6
5.3 Análisis exploratorio de las imágenes DICOM 6
5.4 Ajuste de parámetros 10
5.5 Comparación de algoritmos 10
5.6 Aplicación desarrollada 10

6 Conclusiones **16**

A Estado de integración del informe (uso interno; eliminar antes de entregar) **18**

1 Introducción

Las fracturas de la columna cervical son lesiones potencialmente graves: un diagnóstico tardío puede asociarse a deterioro neurológico. En pacientes adultos con trauma, la tomografía computarizada (TC) es la modalidad de imagen de referencia para su evaluación, y la decisión de solicitarla suele apoyarse en reglas clínicas como NEXUS (Hoffman et al., 2000) y la Canadian C-Spine Rule (Stiell et al., 2001). La lectura de cientos de cortes por estudio es demandante y motivó la competencia **RSNA 2022 Cervical Spine Fracture Detection** (Radiological Society of North America, 2022), cuyo conjunto de datos describen Lin et al. (2023).

Este informe continúa el análisis exploratorio del Proyecto 2 (datos tabulares `train.csv` y `train_bounding_boxes.csv`) y lo extiende con un experimento de aprendizaje profundo reproducible sobre las imágenes DICOM, ejecutado en Kaggle Notebooks por el tamaño del conjunto de datos.

1.1 Problema científico

¿Es posible construir, con recursos de cómputo acotados y una muestra reproducible de estudios de TC de RSNA 2022, un clasificador que estime **a nivel de estudio** la presencia de al menos una fractura cervical (`patient_overall`), y aporta el modelado secuencial de los cortes (BiGRU) una mejora medible frente a una agregación MIL simple?

2 Objetivos

2.1 Objetivo general

Implementar y evaluar, sobre estudios no vistos, un *pipeline* reproducible de preprocesamiento DICOM y clasificación global de fracturas cervicales en TC, y caracterizar la calidad y heterogeneidad de las imágenes que lo alimentan.

2.2 Objetivos específicos

1. Construir una muestra estratificada de 2 019 estudios con particiones por estudio sin fuga (entrenamiento 1 292, validación 323, prueba 404).
2. Implementar el preprocesamiento DICOM (HU, ventana ósea, normalización, 224×224, orden por `ImagePositionPatient`) y auditar la variabilidad de metadatos y su calidad.
3. Entrenar y evaluar ResNet18 + MIL y ResNet18 + BiGRU con las mismas particiones, reportando sensibilidad, especificidad, precisión, F1, exactitud y ROC-AUC con IC 95 %.
4. Seleccionar un modelo con base en resultados de validación y prueba, explicitando la incertidumbre.
5. Desarrollar una aplicación Streamlit que use el mismo preprocesamiento para inferencia.

3 Marco teórico

3.1 Tomografía computarizada, DICOM y unidades Hounsfield

Los estudios se distribuyen en formato DICOM: cada corte axial es un archivo cuya cabecera incluye parámetros de adquisición (`SliceThickness`, `PixelSpacing`, `Rows`/`Columns`, `RescaleSlope`/`RescaleIntercept`, `ImagePositionPatient`, sintaxis de transferencia, etc.). Los

valores de píxel se convierten a unidades Hounsfield (HU) con

$$\text{HU} = \text{valor} \times \texttt{RescaleSlope} + \texttt{RescaleIntercept}.$$

El aire ronda -1000 HU, el agua 0 HU y el hueso cortical supera varios cientos de HU. El *windowing* recorta el intervalo $[L - W/2,\ L + W/2]$ para maximizar el contraste del tejido de interés; aquí se usa una ventana ósea $L = 400$, $W = 1800$ (rango $[-500, 1300]$ HU).

3.2 Procesamiento de imágenes médicas

La heterogeneidad entre instituciones (grosor de corte, tamaño de píxel, protocolo de reescalado, orden de los cortes) obliga a estandarizar la entrada antes de cualquier modelo. Las decisiones de estandarización de este trabajo y su justificación empírica se discuten en la sección 5.3.

3.3 Análisis de las imágenes desde el punto de vista médico

PENDIENTE — Anatomía cervical y fracturas C1–C7

Descripción de las siete vértebras cervicales, mecanismos y patrones de fractura y signos radiológicos relevantes en TC, con referencias indexadas.

Fuente esperada: Documento de revisión bibliográfica del equipo (`revision_bibliografica_fracturas_cervicales.docx`); no se incluye en el repositorio, por lo que su contenido debe integrarse con la fuente original.

3.4 Algoritmos de aprendizaje profundo

Redes residuales. ResNet (He et al., 2016) introduce conexiones residuales que facilitan entrenar redes profundas; una ResNet18 preentrenada en ImageNet (Deng et al., 2009) es un extractor de características ligero. **Aprendizaje de múltiples instancias (MIL).** Con etiqueta solo a nivel de "bolsa" (estudio) y no de "instancia" (corte), MIL agrega puntuaciones de instancias en una puntuación de bolsa (Ilse et al., 2018); un estudio positivo puede tener la mayoría de cortes sin fractura visible, por lo que conviene agregar con los k logits más altos. **Modelos secuenciales.** Una GRU (Cho et al., 2014) bidireccional procesa la secuencia de *embeddings* de cortes ordenados por z en ambos sentidos, pudiendo capturar contexto anatómico entre cortes vecinos.

3.5 Evaluación

El ROC-AUC resume la discriminación independiente del umbral (Hanley and McNeil, 1982); el umbral operativo se fija con el índice de Youden $J = \text{sensibilidad} + \text{especificidad} - 1$ (Youden, 1950) en validación, y la incertidumbre del AUC se estima con *bootstrap* percentil (Efron and Tibshirani, 1993).

4 Metodología

4.1 Pasos seguidos por el grupo

1. Análisis exploratorio de los datos tabulares (Proyecto 2, primera entrega).
2. Revisión bibliográfica y selección de algoritmos.

3. Preprocesamiento DICOM y auditoría de metadatos (EDA de imágenes, sección 5.3).
4. Entrenamiento y evaluación de dos modelos con las mismas particiones.
5. Comparación estadística, selección y desarrollo de la aplicación interactiva.

4.2 Datos y particiones

Se usan `train.csv` (2 019 estudios; `patient_overall` y C1–C7) y las imágenes DICOM de la competencia (Radiological Society of North America, 2022). El volumen del conjunto de imágenes (del orden de cientos de GB) llevó a procesar los estudios dentro de Kaggle Notebooks, sin descargarlos localmente. La muestra comprende los 2 019 estudios, estratificados por `patient_overall` (semilla 42), con particiones *por estudio*: entrenamiento 1 292 (615 positivos), validación 323 (154) y prueba 404 (192); en RSNA 2022 cada estudio corresponde a un paciente distinto, por lo que no hay pacientes compartidos entre particiones.

4.3 Preprocesamiento

Paso	Implementación
Lectura	`pydicom`; decodificación JPEG Lossless con `pylibjpeg`/GDCM
Intensidades	HU = píxel × `RescaleSlope` + `RescaleIntercept`, leídos por archivo
Fotometría	MONOCHROME1 invertido; MONOCHROME2 sin cambios
Ventana	ósea $L = 400$, $W = 1800$, normalización lineal a $[0, 1]$
Tamaño	224×224 (`INTER_AREA`), sin remuestreo isotrópico
Selección de cortes	48 posiciones equiespaciadas entre el 5 % y el 95 % del rango de instancias; entrada 2.5D con vecinos a ±2 mm
Orden	por `ImagePositionPatient[2]` (z) ascendente, no por número de instancia

Cuadro 1: Pipeline de preprocesamiento (configuración v2, `artifacts/v2/config/preprocessing.json`).

4.4 Herramientas y recursos de cómputo

El entrenamiento se ejecutó en Kaggle Notebooks con GPU T4. Se usaron Python, `pydicom`, OpenCV, PyTorch (Paszke et al., 2019), Streamlit y Plotly; las versiones exactas están en `experimento_dl/requirements.txt`.

4.5 Selección de algoritmos, arquitecturas y configuración de entrenamiento

PENDIENTE — Metodología de entrenamiento (responsable GPU)

Justificación de la selección de algoritmos, descripción de los Modelos A (ResNet18 + MIL) y B (ResNet18 + BiGRU), hiperparámetros, criterio de selección de época y umbral, y ajuste de parámetros. El borrador previo (`INFORME_TECNICO.md`, §6.5–6.7) corresponde a la configuración v1 (24 cortes, 160 estudios) y no debe copiarse sin actualizar a v2.

Fuente esperada: Texto de la responsable GPU; configuración en `artifacts/v2/config/model_*.json`.

5 Resultados y análisis de resultados

5.1 Características del conjunto de datos original

El conjunto tabular contiene 2019 estudios en `train.csv`: 961 con fractura (`patient_overall` = 1; 47.6 %) y 1058 sin fractura. Solo 235 estudios (11.6 %) cuentan con *bounding boxes* (7 217 anotaciones), todas en estudios positivos (primera entrega del Proyecto 2). Las imágenes son estudios de TC en formato DICOM con entre 69 y 1082 cortes por estudio (mediana 314).

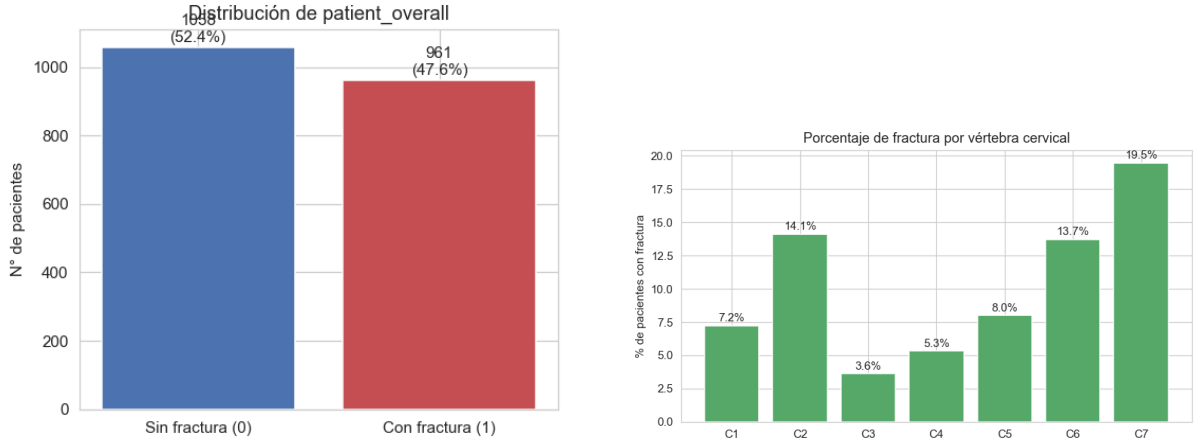


Figura 1: Análisis exploratorio tabular (primera entrega): distribución de la variable objetivo `patient_overall` y frecuencia de fractura por vértebra.

5.2 Limpieza y preprocesamiento

En los CSV no hubo valores nulos ni filas duplicadas, `StudyInstanceUID` es único y `patient_overall` es consistente con la suma de C1–C7, por lo que no se aplicaron correcciones a las etiquetas. En las imágenes, la variabilidad de metadatos no se corrige en los archivos sino en el *pipeline* (sección 5.3): HU calculadas con el `RescaleSlope`/`RescaleIntercept` de cada archivo, ordenamiento por posición z y redimensionado a 224×224.

5.3 Análisis exploratorio de las imágenes DICOM

Fuente y tamaño de muestra. El análisis usa la auditoría del *pipeline* (auditoría del pipeline (artifacts/v2/results/dicom_metadata.csv.gz)): 2019 estudios y 96912 cortes (los 48 centrales de cada estudio). El número de cortes por estudio es el total de archivos del estudio; el resto de metadatos proviene únicamente de esos 48 cortes. El notebook `notebooks/02_eda_imagenes.ipynb` y el script `scripts/eda_metadatos_dicom.py` permiten repetir el análisis leyendo las cabeceras de *todos* los cortes de una muestra estratificada (semilla 42) directamente en Kaggle.

Variable	Media	D. E.	Mín.	Mediana	Máx.
Cortes por estudio	352.452	132.010	69.000	314.000	1082.000
SliceThickness (mm)	0.731	0.185	0.488	0.625	1.000
PixelSpacing (mm)	0.328	0.078	0.190	0.312	0.713
Espaciado z medido (mm)	0.626	0.204	0.312	0.625	2.626

Cuadro 2: Estadística descriptiva por estudio (2019 estudios).

Estadística descriptiva. El grosor de corte toma pocos valores discretos (mediana 0.625 mm, máximo 1 mm, en línea con el criterio de inclusión del conjunto de datos de grosor ≤ 1 mm; Lin et al., 2023), mientras que el tamaño de píxel varía entre 0.19 y 0.713 mm; el número de cortes cubre un rango de más de un orden de magnitud. Tras redimensionar a 224×224, el tamaño físico del píxel resultante varía entre estudios, pues no se remuestrea de forma isotrópica.

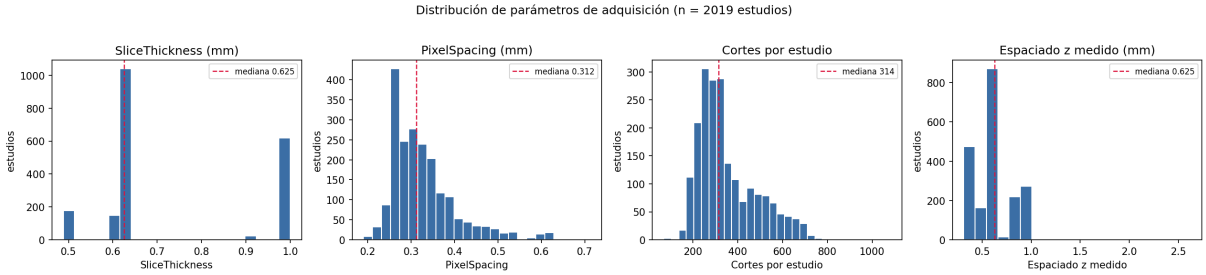


Figura 2: Distribuciones de cortes por estudio, SliceThickness, PixelSpacing y espaciado z medido.

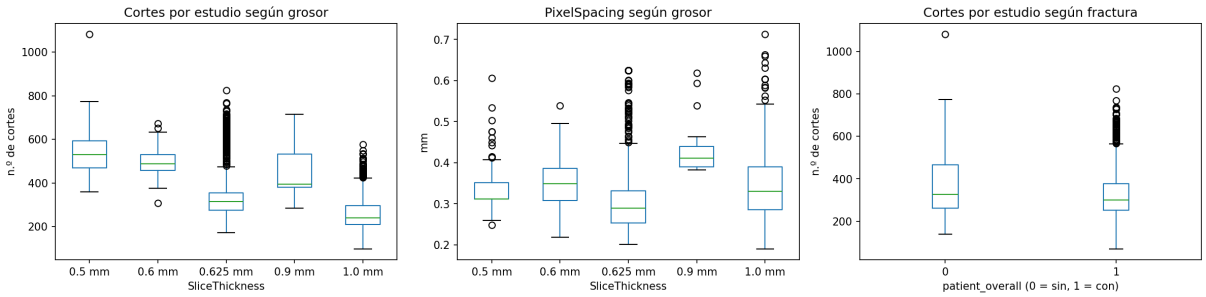


Figura 3: Comparación de parámetros de adquisición según `patient_overall` (descriptiva; sin prueba de hipótesis).

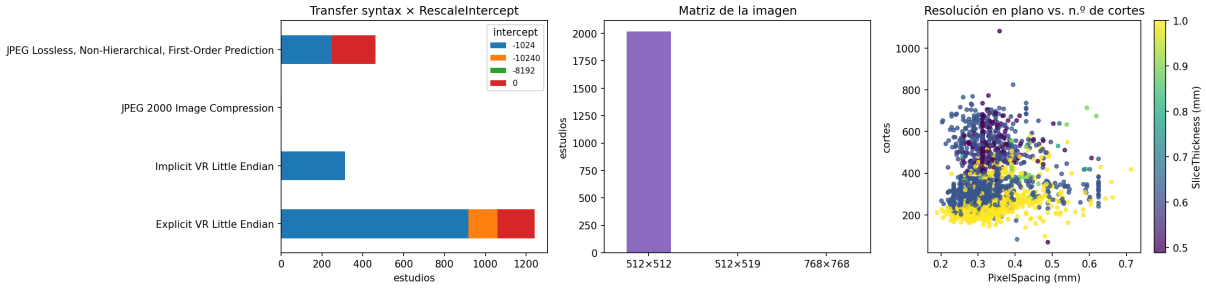


Figura 4: Protocolos de reescalado, sintaxis de transferencia y resolución de matriz.

Comprobación	Estudios	%
Matriz distinta de 512×512	3	0.15
RescaleIntercept $\notin \{-1024, 0\}$ (p. ej. $-8192/-10240$)	144	7.13
RescaleSlope $\neq 1$	141	6.98
Dimensiones de matriz variables dentro del estudio	0	0.00
Slope/intercept variables dentro del estudio	0	0.00
SliceThickness variable dentro del estudio	0	0.00
BitsStored fuera de $\{12, 16\}$	0	0.00
PhotometricInterpretation $\neq$ MONOCHROME2	0	0.00
Atípico (IQR×1.5) en n.° de cortes	27	1.34
Atípico (IQR×1.5) en SliceThickness	0	0.00
Atípico (IQR×1.5) en PixelSpacing	111	5.50
Atípico (IQR×1.5) en espaciado z	2	0.10

Cuadro 3: Comprobaciones de calidad sobre los metadatos. Los umbrales de atípicos usan IQR×1.5.

Valores atípicos y metadatos inconsistentes. Los hallazgos relevantes para el preprocesamiento son: (i) 144 estudios (7.13 %) con `RescaleIntercept` distinto de -1024 y 0: 141 con intercept -10240 y `RescaleSlope` $= 10$, y 3 con intercept -8192; (ii) 3 estudios que no son 512×512; (iii) ningún estudio con dimensiones, grosor o reescalado variables *dentro* del estudio, ni fotometría distinta de MONOCHROME2; (iv) 111 estudios con `PixelSpacing` atípico y 27 con número de cortes atípico. Que las HU resultantes de los estudios con reescalado atípico sean plausibles se comprueba con píxeles reales y no con metadatos (véase más abajo).

Orden de los cortes y auditoría del *pipeline*. El sentido de z respecto al número de instancia no es constante: 1821 estudios son decrecientes, 197 crecientes y 1 mixto; 1 estudio no es monótono. Los estudios con espaciado z irregular o no monótono son …20756, …8362, …8693 (identificados por los últimos dígitos de su UID). Esto justifica ordenar por `ImagePositionPatient[2]` y no por número de instancia. El sentido creciente es más frecuente en estudios positivos (12.6 % frente a 7.3 % en negativos; χ^2, $p = 8.4e-05$); es una asociación descriptiva que podría reflejar diferencias de protocolo o institución, que los metadatos disponibles no permiten confirmar. El preprocesamiento de los 2019 estudios terminó con 0 fallos; el tiempo por estudio fue de 2.52 s en promedio (mediana 2.19 s, máximo 5.2 s) y los estudios comprimidos con JPEG Lossless tardaron aproximadamente el doble que los no comprimidos (mediana 4.07 s frente a 2.11 s con Explicit VR Little Endian).

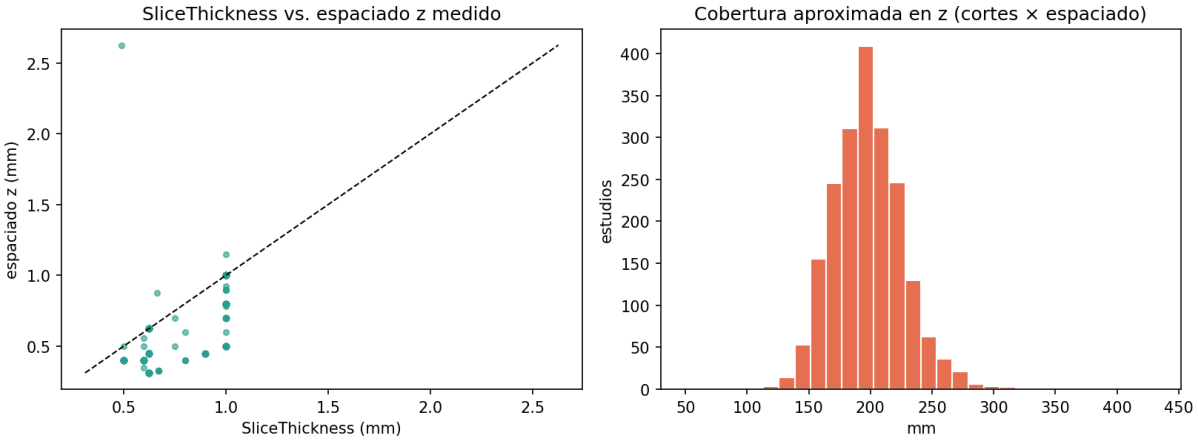


Figura 5: Consistencia del eje z entre estudios.

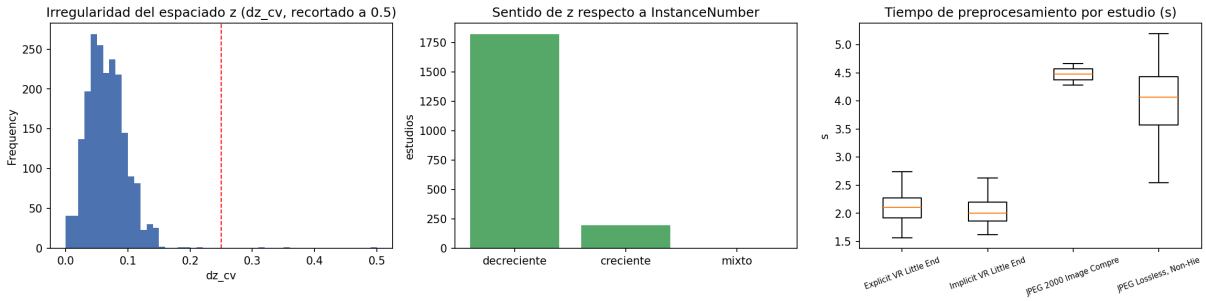


Figura 6: Auditoría del *pipeline*: irregularidad del espaciado z, sentido de z y tiempo de preprocesamiento por sintaxis de transferencia.

Ejemplos reales antes y después del preprocesamiento. Las figuras siguientes provienen del *pipeline* de entrenamiento (`artifacts/v2/results/figures/`) y muestran el corte en HU crudo, el histograma con la ventana ósea y el resultado final.

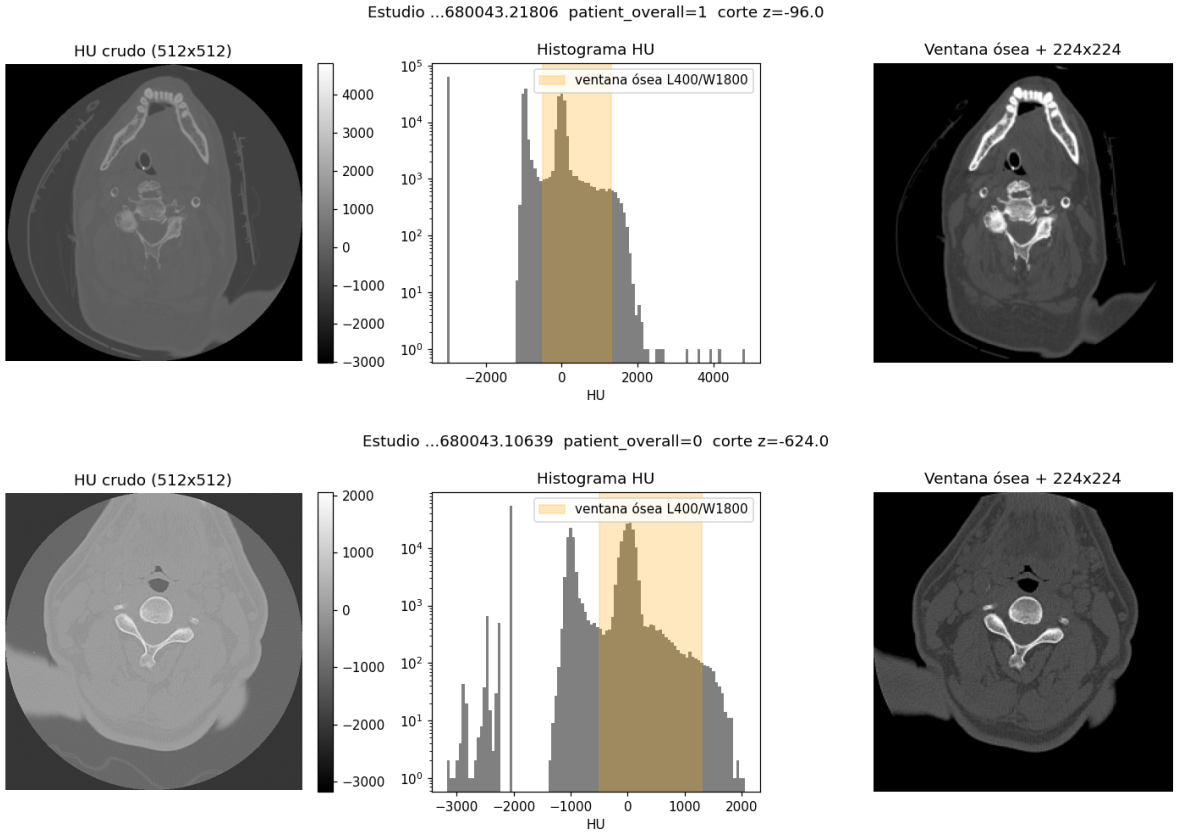


Figura 7: Antes y después del preprocesamiento en un estudio positivo (arriba) y uno negativo (abajo).

PENDIENTE — Intensidades (HU) por grupo de reescalado y diferencias de adquisición

Histogramas de HU del corte central de una submuestra, con todos los estudios de reescalado atípico y estudios aleatorios, y la comparación antes/después sobre ellos (sección 5 del notebook 02).

Fuente esperada: Ejecución de `notebooks/02_eda_imagenes.ipynb` en Kaggle con la competencia como entrada (produce `intensidades_corte_central.csv` y las figuras 05

y 06).

Limitaciones del EDA de imágenes.

- Solo se dispone de las cabeceras de 48 cortes centrales por estudio; no se pueden detectar huecos en z ni cabeceras atípicas fuera de esos cortes.
- El espaciado z medido es la distancia entre dos cortes consecutivos *muestreados*, no una mediana del estudio. Por ello la comparación grosor vs. espaciado z (879 estudios, 43.54 %) no es concluyente y se excluye de la tabla de calidad hasta confirmarla con cabeceras completas.
- Las comprobaciones sobre cabeceras no sustituyen una revisión clínica de la calidad de imagen ni miden artefactos (metal, movimiento).
- La comparación por `patient_overall` es descriptiva, sin control de confusores de protocolo.

5.4 Ajuste de parámetros

PENDIENTE — Ajuste de parámetros de cada algoritmo (responsable GPU)

Qué parámetros se ajustaron, cómo y con qué efecto sobre el rendimiento.

Fuente esperada: Texto de la responsable GPU; historiales en `artifacts/v2/results/history_*.csv`.

5.5 Comparación de algoritmos

PENDIENTE — Comparación de modelos y selección (P3)

Tabla comparativa de métricas, pruebas estadísticas pareadas, tiempos y figuras estáticas (ROC, matrices de confusión, distribución de probabilidades) con interpretación y modelo seleccionado.

Fuente esperada: Análisis y redacción de P3 (Hansel); datos en `artifacts/v2/results/` y `notebooks/03_evaluacion.ipynb` (rama `main`).

5.6 Aplicación desarrollada

Se desarrolló una aplicación web interactiva con Streamlit que integra la exploración de datos, el preprocesamiento, la predicción sobre estudios nuevos y la comparación de los dos modelos entrenados (A: ResNet18 + MIL; B: ResNet18 + BiGRU). Se ejecuta con `streamlit run experimento_dl/app_streamlit.py`; su documentación está en `docs/app/APP_STREAMLIT.md` y la demostración de la integración en `notebooks/04_integracion_app.ipynb`.

Las tecnologías elegidas y su justificación se resumen en el cuadro 4.

Componente	Justificación
Streamlit	Interfaz web en Python puro, sin desarrollo *front-end* separado; permite reutilizar directamente los módulos del *pipeline* y cachear modelos y lecturas DICOM.
Plotly	Gráficas interactivas (zoom, *hover*, selección de series) para explorar métricas y distribuciones; con un interruptor se sustituyen por las figuras estáticas PNG del entrenamiento.
pydicom, pylibjpeg/GDCM	Lectura de los mismos DICOM que en entrenamiento, incluidos los comprimidos con JPEG Lossless.
PyTorch	Carga de los checkpoints en modo seguro (`weights_only`) e inferencia en CPU o GPU (Paszke et al., 2019).
`inference.py` y `metrics_eval.py`	Preprocesamiento e inferencia del *pipeline* de entrenamiento, y métricas e intervalos bootstrap del módulo de evaluación independiente; la aplicación no reimplementa ninguno de los dos.

Cuadro 4: Tecnologías de la aplicación y justificación de su elección.

Coherencia con el entrenamiento. La aplicación no reimplementa el preprocesamiento ni las arquitecturas: usa `inference.py`, que reconstruye la configuración guardada con cada checkpoint (48 posiciones 2.5D, ventana ósea $L = 400/W = 1800$, 224×224, orden por `ImagePositionPatient[2]`). En el notebook de integración se comprobó que el tensor que recibe el modelo en la aplicación coincide en forma ($48 \times 3 \times 224 \times 224$), tipo y parámetros con el de entrenamiento, y que no depende del orden en que se suban los archivos. Antes de cargar un checkpoint se verifica su huella SHA-256 frente a `artifacts/v2/MANIFEST.json`.

Funcionalidades. La aplicación se organiza en ocho pestañas: (1) exploración de `train.csv` y de los metadatos DICOM (figura 8); (2) pasos y ejemplos del preprocesamiento; (3) visor DICOM, que muestra cada corte en HU crudas y tras la ventana ósea, su histograma, los metadatos y el tensor de entrada del modelo (figura 9); (4) predicción; (5) métricas por modelo y conjunto; (6) comparación de modelos; (7) estado de los artefactos, y (8) limitaciones. Un panel lateral permite alternar entre gráficas interactivas y estáticas, y mostrar u ocultar cada tipo de gráfica.

Predicción de nuevas entradas. El usuario sube los archivos DICOM de un estudio, o selecciona uno o varios estudios locales, y elige el Modelo A, el B o ambos. Cada resultado muestra la probabilidad, la clase según el umbral fijado en validación (índice de Youden; Youden, 1950), los avisos de calidad de la entrada (archivos ilegibles, estudios mezclados, menos cortes que posiciones del modelo o ausencia de `RescaleSlope`) y un descargo explícito: es una clasificación global por estudio, sin localización y sin validación clínica. Si se ejecutan ambos modelos, la aplicación indica si coinciden, la diferencia de probabilidades y el percentil de cada probabilidad en la distribución del conjunto de prueba, por clase real. Si el estudio pertenece a las particiones del experimento, compara la probabilidad obtenida con la registrada en la evaluación, lo que verifica que el despliegue reproduce el modelo evaluado; si pertenece a entrenamiento, advierte que no es una evaluación independiente. La etiqueta real, cuando se conoce, se muestra aparte y rotulada como tal. Mientras los checkpoints no están disponibles, la pestaña muestra el estado PENDIENTE y no genera probabilidades (figura 10); las predicciones del conjunto de prueba ya calculadas en la evaluación se pueden consultar estudio por estudio.

Comparación interactiva de modelos. El usuario elige conjuntos y métricas; la aplicación presenta barras agrupadas, la diferencia $\mathrm{B} - \mathrm{A}$, las pruebas pareadas (DeLong, bootstrap y McNemar), las curvas ROC con el punto de operación, la distribución de probabilidades por

clase y la dispersión de las probabilidades de ambos modelos por estudio (figura 11). Un control de umbral recalcula las métricas sobre las predicciones de prueba, con intervalos de confianza bootstrap al 95 % (Efron and Tibshirani, 1993); esta exploración es descriptiva, pues los umbrales oficiales se fijaron en validación. Todos los valores provienen de los artefactos reales del entrenamiento (`artifacts/v2/`); si falta alguno, se muestra PENDIENTE y no se generan valores sustitutos.

Pruebas. La aplicación se validó con 25 pruebas automáticas propias: consistencia de las métricas con las predicciones, entradas inválidas (sin archivos, no DICOM, vacíos, estudios mezclados), rechazo de checkpoints ausentes o alterados, forma de la entrada, flujo completo de predicción y comparación en la interfaz, e inferencia por lotes. Las pruebas de interfaz usan checkpoints con pesos aleatorios únicamente para ejercitar el código; con ellos, la verificación de reproducibilidad señala correctamente que no coinciden con la evaluación. Además, se revisaron las ocho pestañas en el navegador sin errores.

PENDIENTE — Inferencia con los checkpoints reales (P1)

La interfaz y la verificación están implementadas, pero la inferencia sobre estudios nuevos no se ha ejecutado con los checkpoints reales (`mil_final.pt`, `bigru_final.pt`). Tras recibirlos, se reporta la reproducibilidad frente a la evaluación, el tiempo por estudio y el acuerdo A/B, y se actualiza la figura 10.

Fuente esperada: `docs/app/validacion_inferencia.json`, generado por `experimento_dl/tools/validar_inferencia.py` con los checkpoints de la responsable GPU.

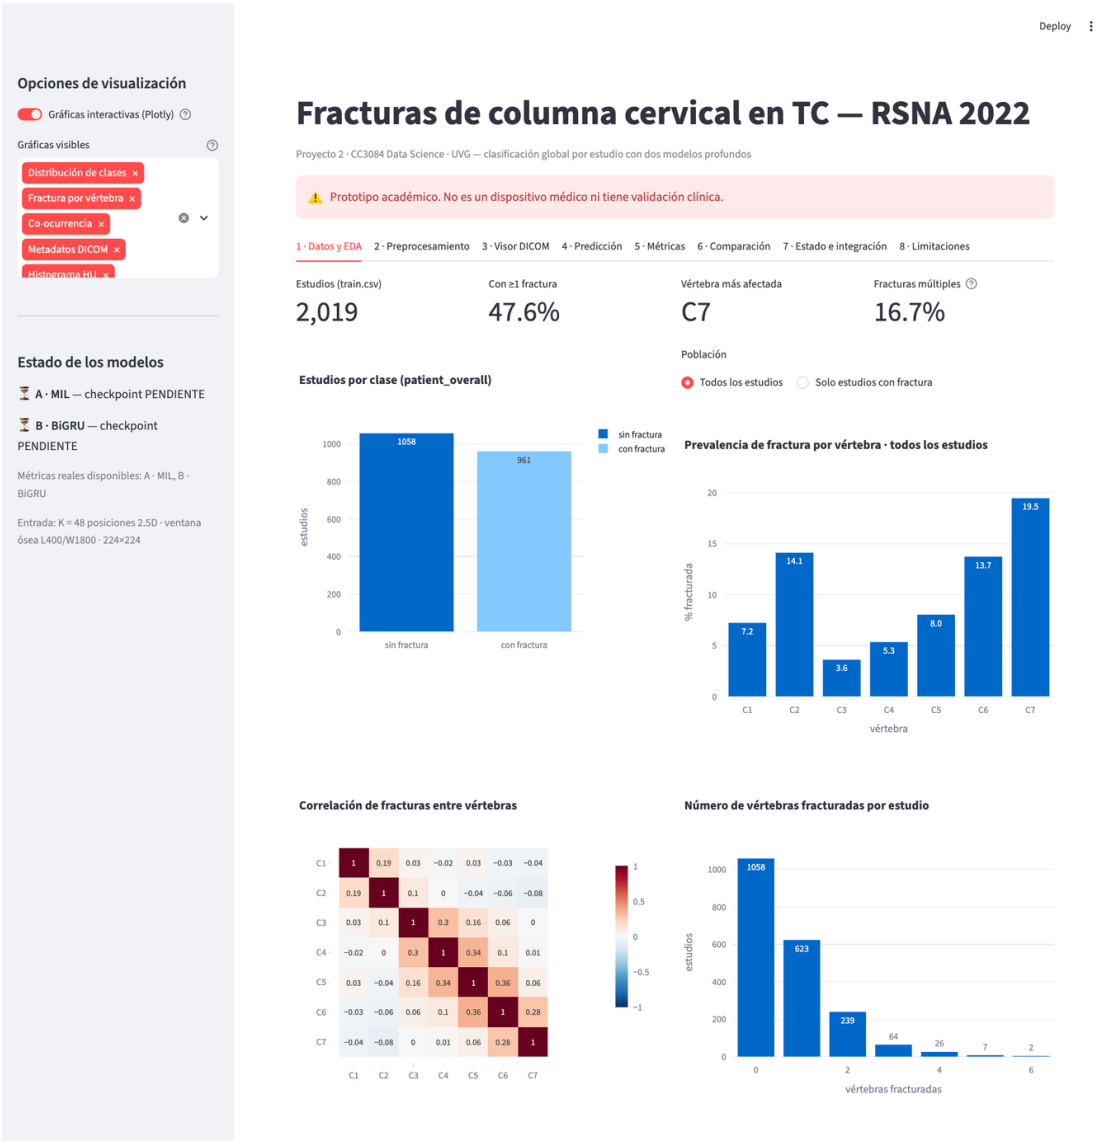


Figura 8: Aplicación, pestaña 1: exploración interactiva de `train.csv`, particiones y metadatos DICOM.

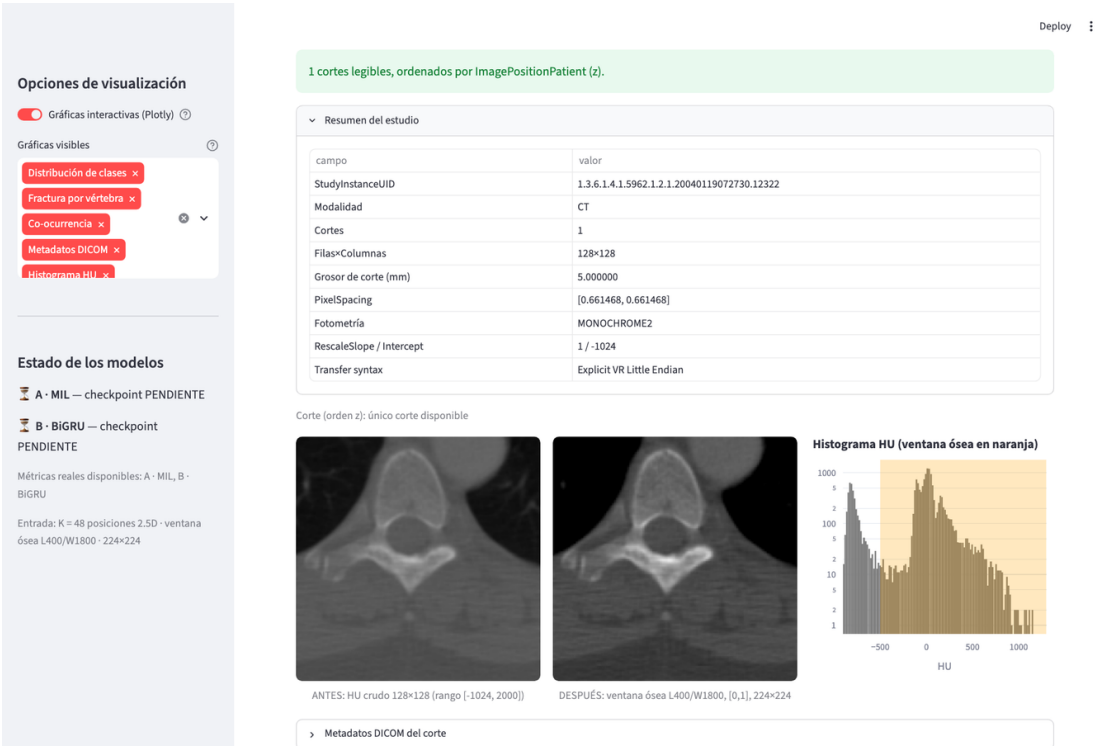


Figura 9: Aplicación, pestaña 3: visor DICOM con el corte en HU crudas, tras la ventana ósea y su histograma (corte de TC de prueba de `pydicom`).

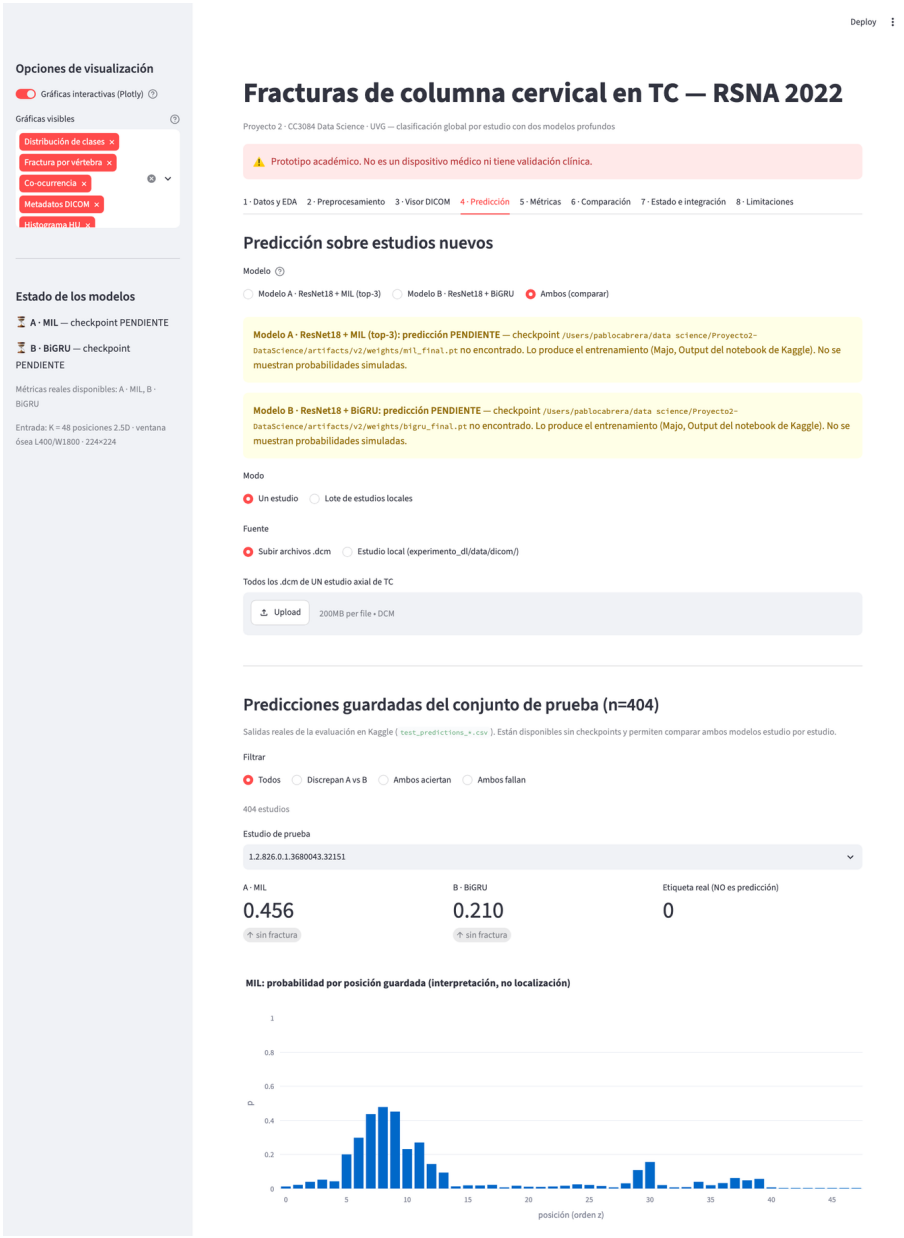


Figura 10: Aplicación, pestaña 4: selección de modelo (estado PENDIENTE sin checkpoints) y consulta de las predicciones de prueba ya calculadas en la evaluación.

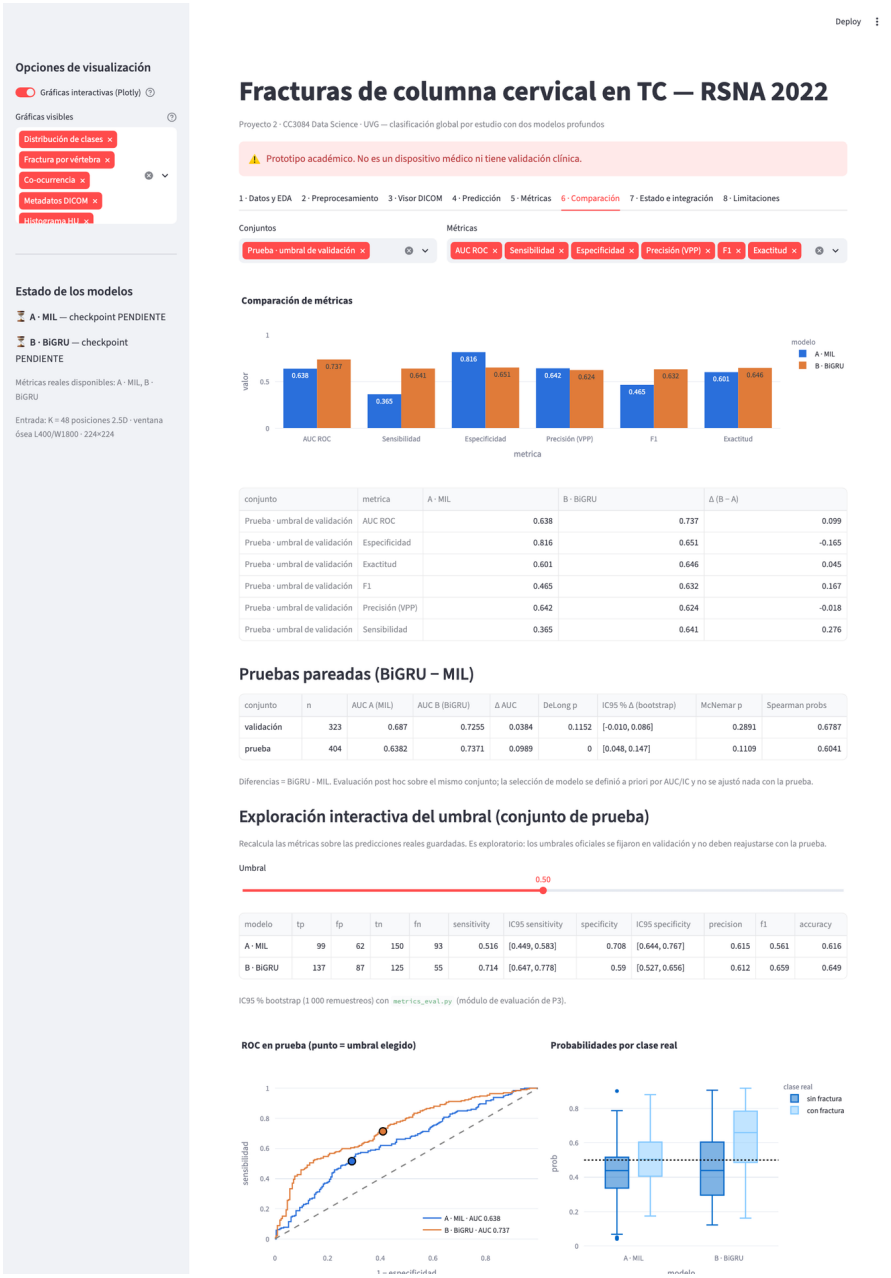


Figura 11: Aplicación, pestaña 6: comparación interactiva de los modelos A y B en el conjunto de prueba.

6 Conclusiones

PENDIENTE — Conclusiones (P3)

Cómo se cumplieron cada uno de los objetivos de la sección 2 y discusión de la efectividad de los algoritmos. Se redactan solo a partir de los resultados reales de la comparación.

Fuente esperada: Redacción de P3 (Hansel) a partir de `artifacts/v2/results/`.

Conclusiones del EDA de imágenes (P2)

La heterogeneidad de los metadatos DICOM es real y medible: reescalado atípico en 7.13 % de los estudios, tamaños de píxel entre 0.19 y 0.713 mm, sentido de z variable y compresión distinta entre estudios. Las decisiones del *pipeline* (HU por archivo, orden por z, ventana ósea) responden a esa heterogeneidad. Quedan abiertas dos verificaciones que requieren píxeles: la plausibilidad de las HU en los estudios con reescalado atípico y el análisis de intensidades por grupo de adquisición (ver el recuadro de pendientes en la sección 5.3).

Limitaciones generales

Una sola partición y una sola semilla; 48 posiciones por estudio de cientos de cortes (la fractura puede no estar muestreada); clasificador global que no localiza la fractura; sin remuestreo isotrópico; sin validación clínica ni externa, por lo que las métricas no son comparables con las de la competencia.

Referencias

Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., and Bengio, Y. (2014). Learning phrase representations using RNN encoder–decoder for statistical machine translation. In *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1724–1734.

Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., and Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. In *2009 IEEE Conference on Computer Vision and Pattern Recognition*, pages 248–255.

Efron, B. and Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall.

Hanley, J. A. and McNeil, B. J. (1982). The meaning and use of the area under a receiver operating characteristic (ROC) curve. *Radiology*, 143(1):29–36.

He, K., Zhang, X., Ren, S., and Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 770–778.

Hoffman, J. R., Mower, W. R., Wolfson, A. B., Todd, K. H., and Zucker, M. I. (2000). Validity of a set of clinical criteria to rule out injury to the cervical spine in patients with blunt trauma. *New England Journal of Medicine*, 343(2):94–99.

Ilse, M., Tomczak, J., and Welling, M. (2018). Attention-based deep multiple instance learning. In *Proceedings of the 35th International Conference on Machine Learning*, pages 2127–2136. PMLR.

Lin, H. M., Colak, E., Richards, T., Kitamura, F. C., Prevedello, L. M., Talbott, J., Ball, R. L., Gumeler, E., Yeom, K. W., Hamghalam, M., Simpson, A., Strika, J., Bulja, D., Angkurawaranon, S., Pérez-Lara, A., Gómez-Alonso, M., Ortiz Jiménez, J., Peoples, J., Law, M., Dogan, H., Altinmakas, E., Youssef, A., Mahfouz, Y., Kalpathy-Cramer, J., and Flanders, A. E. (2023). The RSNA cervical spine fracture CT dataset. *Radiology: Artificial Intelligence*, 5(5):e230034.

Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., et al. (2019). PyTorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems 32*, pages 8024–8035.

Radiological Society of North America (2022). RSNA 2022 cervical spine fracture detection [competencia].

Stiell, I. G., Wells, G. A., Vandemheen, K. L., Clement, C. M., Lesiuk, H., De Maio, V. J., et al. (2001). The Canadian C-spine rule for radiography in alert and stable trauma patients. *JAMA*, 286(15):1841–1848.

Youden, W. J. (1950). Index for rating diagnostic tests. *Cancer*, 3(1):32–35.

A Estado de integración del informe (uso interno; eliminar antes de entregar)

Sección	Responsable	Estado
Introducción, marco teórico (TC, DL, evaluación)	P2 (integración)	Redactado a partir del borrador del equipo
Anatomía y fracturas (marco teórico médico)	Revisión bibliográfica	Pendiente de integrar desde el .docx
Datos, particiones, preprocesamiento	P2 / GPU	Redactado con cifras v2 (verificar con GPU)
Metodología de entrenamiento y ajuste	Responsable GPU	Pendiente
EDA de imágenes (metadatos, orden z, tiempos)	P2	Con cifras reales de la auditoría
EDA de imágenes (intensidades HU, antes/después propios)	P2	Pendiente de ejecución en Kaggle
Comparación de modelos y conclusiones	P3	Pendiente
Aplicación y capturas	P1	Redactado con capturas reales; falta la inferencia con checkpoints reales
Resumen	Todos	Pendiente (al cierre)

Cuadro 5: Matriz de integración. Los recuadros amarillos del texto son los espacios reservados.