

UNIVERSIDAD DEL VALLE DE GUATEMALA

Ing. Lynette Garcia Pérez

Data Science



Proyecto 2: Análisis Exploratorio

Pablo Andres Cabrera - 231156

Hansel Andre Lopez - 19026

Pablo Jose Mendez - 23975

Maria Jose Yee - 231193

Guatemala, septiembre de 2026

Índice

1. Situacion Problemática	3
2. Problema Científico	3
3. Objetivos	3
3.1. Objetivo general	3
3.2. Objetivos específicos	3
4. Descripción de los datos	3
4.1. Origen y estructura general	3
4.2. Descripción de las variables	4
4.3. Operaciones de limpieza y verificación de calidad	4
5. Análisis Exploratorio	5
5.1. Estructura general de los datos	5
5.1.1. <code>train.csv</code>	5
5.1.2. <code>trainboundingboxes.csv</code>	5
5.2. Resumen numérico y tablas de frecuencia	6
5.2.1. Variable objetivo: <code>patientoverall</code>	6
5.2.2. Frecuencia de fractura por vértebra (C1–C7)	7
5.2.3. Número de vértebras fracturadas por paciente	7
5.2.4. Resumen numérico de las bounding boxes	8
5.2.5. Cajas por estudio (solo estudios anotados)	9
5.3. Cruce de variables clave	10
5.3.1. Consistencia entre <code>patientoverall</code> y la suma de C1–C7	10
5.3.2. Correlación entre vértebras fracturadas (co-ocurrencia)	10
5.3.3. Relación entre bounding boxes y severidad de la fractura	11
5.3.4. Presencia de bounding boxes vs diagnóstico general	12
5.3.5. Distribución del corte anotado (<code>slicenumber</code>)	13
6. Hallazgos y Conclusiones	13

1. Situacion Problemática

El reto seleccionado aborda la detección de fracturas en la columna cervical mediante imágenes médicas. Estas lesiones pueden producir complicaciones neurológicas graves cuando no se identifican y atienden oportunamente. Su detección puede ser difícil debido a la complejidad de las imágenes, la variación en la apariencia de las fracturas y la presencia de condiciones como osteoporosis o cambios degenerativos.

La competencia RSNA 2022 Cervical Spine Fracture Detection busca identificar fracturas en las siete vértebras cervicales, C1 a C7, a partir de estudios de tomografía computarizada. También se debe determinar si el paciente presenta al menos una fractura cervical. La revisión manual de una gran cantidad de imágenes puede requerir mucho tiempo y estar sujeta a errores humanos, por lo que el análisis de datos y las técnicas de visión artificial pueden servir como apoyo para localizar patrones relevantes.

2. Problema Científico

¿Cómo pueden analizarse las imágenes de tomografía computarizada y las etiquetas asociadas del conjunto de datos RSNA 2022 para identificar patrones relacionados con la presencia y localización de fracturas en las vértebras cervicales C1-C7?

3. Objetivos

3.1. Objetivo general

Realizar un análisis exploratorio del conjunto de datos RSNA 2022 Cervical Spine Fracture Detection para identificar patrones y características relacionadas con la presencia y localización de fracturas en las vértebras cervicales.

3.2. Objetivos específicos

Describir la estructura del conjunto de datos, incluyendo los estudios disponibles, las imágenes médicas y las etiquetas correspondientes a las vértebras C1-C7 y a la variable patient overall. Analizar la distribución de los casos con y sin fractura, identificando posibles desbalances entre las clases y entre las diferentes vértebras cervicales. Explorar visualmente las imágenes de tomografía computarizada y las variables disponibles para reconocer características que puedan estar relacionadas con la detección de fracturas. Identificar valores faltantes, inconsistencias u otras situaciones que deban considerarse durante la limpieza y el preprocesamiento de los datos.

4. Descripción de los datos

4.1. Origen y estructura general

Los datos provienen de la competencia RSNA 2022 Cervical Spine Fracture Detection (Kaggle), cuyo objetivo es detectar y localizar fracturas en las siete vértebras cervicales (C1–C7) a partir de estudios de tomografía computarizada (CT). El proyecto trabaja con dos archivos tabulares que contienen los metadatos y anotaciones de esos estudios (no las imágenes DICOM en sí):

Archivo	Observaciones	Variables	Granularidad
train.csv	2,019	9	1 fila = 1 paciente / estudio (<u>StudyInstanceUID</u>)
train_bounding_boxes.csv	7,217	6	1 fila = 1 caja delimitadora anotada en un <u>slice</u>

Ambos archivos se relacionan mediante la clave StudyInstanceUID. Es importante notar que solo 235 de los 2,019 estudios (11.6%) cuentan con bounding boxes anotados; el resto tiene únicamente la etiqueta de diagnóstico a nivel de paciente/vértebra, sin localización espacial de la fractura.

4.2. Descripción de las variables

train-bounding-boxes.csv — anotaciones espaciales, a nivel de slice/imagen

Variable	Tipo	Descripción
<u>StudyInstanceUID</u>	Texto (clave foránea)	Enlaza la caja con el estudio correspondiente en train.csv.
x, y	Numérica continua (<u>float</u>)	Coordenadas (en píxeles) de la esquina de la caja delimitadora dentro del <u>slice</u> .
<u>width</u> , <u>height</u>	Numérica continua (<u>float</u>)	Ancho y alto (en píxeles) de la caja delimitadora.
<u>slice_number</u>	Numérica discreta (<u>int</u>)	Número del corte (<u>slice</u>) de la CT en el que se ubica la caja.

En total: 9 variables en train.csv (1 identificador + 8 binarias) y 6 variables en train-bounding-boxes.csv (1 identificador + 5 numéricas), sobre 2,019 pacientes y 7,217 anotaciones de caja, respectivamente.

4.3. Operaciones de limpieza y verificación de calidad

Se realizó un chequeo sistemático de calidad antes del análisis exploratorio. No fue necesario aplicar correcciones, ya que los datos llegaron consistentes; los hallazgos de la verificación fueron:

- Valores nulos: cero valores faltantes en las 9 columnas de train.csv y en las 6 de train-bounding-boxes.csv.
- Duplicados: ninguna fila duplicada en ninguno de los dos archivos; StudyInstanceUID es único en train.csv (2,019 valores únicos para 2,019 filas), y no existen pares (StudyInstanceUID, slice-number) repetidos en train-bounding-boxes.csv.
- Integridad referencial: el 100% de los StudyInstanceUID presentes en train-bounding-boxes.csv existen en train.csv (no hay bounding boxes «huérfanas»).
- Validez de rangos: las variables binarias (patient-overall, C1–C7) solo toman valores 0,1. Las coordenadas y dimensiones de las cajas (x, y, width, height) son siempre positivas, consistente con medidas físicas en píxeles; slice-number va de 26 a 483, un rango razonable para un volumen CT.

- Consistencia lógica entre variables: se verificó que `patient-overall` es perfectamente coherente con la suma de `C1–C7` — no existe ningún paciente marcado como «sin fractura» que tenga alguna vértebra fracturada, ni ninguno marcado «con fractura» sin ninguna vértebra afectada. Esto confirma que `patient-overall` es una variable derivada/agregada de `C1–C7`.

Como parte del preprocesamiento (no de limpieza, dado que no había errores que corregir) se crearon variables derivadas para facilitar el análisis exploratorio posterior:

- `n-fracturas`: suma de `C1–C7` por paciente, indicando severidad (número de vértebras afectadas).
- `tiene-bbox`: bandera booleana que indica si el estudio del paciente cuenta con al menos una anotación en `train-bounding-boxes.csv`.
- `n-boxes`: conteo de cajas anotadas por estudio, obtenido agrupando `train-bounding-boxes.csv` por `StudyInstanceUID` y uniéndolo (`merge`) a `train.csv`.

5. Análisis Exploratorio

Archivos analizados: `train.csv` y `trainboundingboxes.csv`

5.1. Estructura general de los datos

5.1.1. `train.csv`

Aspecto	Valor
N° de observaciones (pacientes/estudios)	2,019
N° de variables	9
Valores nulos	0 (ninguna variable tiene datos faltantes)
Duplicados de <code>StudyInstanceUID</code>	0

Variable	Tipo	Descripción / Naturaleza
<code>StudyInstanceUID</code>	Texto (identificador)	Identificador único del estudio/paciente
<code>patientoverall</code>	Numérica discreta (binaria 0/1)	Variable objetivo: indica si el paciente tiene al menos una fractura cervical
<code>C1 ... C7</code>	Numérica discreta (binaria 0/1)	Indica si esa vértebra específica (<code>C1</code> a <code>C7</code>) presenta fractura

Aunque están codificadas como `int64`, `patientoverall` y `C1–C7` son en realidad variables categóricas binarias (indicadoras), no cuantitativas continuas.

5.1.2. `trainboundingboxes.csv`

Aspecto	Valor
N° de observaciones (cajas delimitadoras)	7,217
N° de variables	6
Valores nulos	0
N° de estudios distintos representados	235 de los 2,019 totales (11.6%)




Figura 1: Distribución de la variable objetivo patientoverall.

Variable	Tipo	Descripción
StudyInstanceUID	Texto (identificador)	Enlaza con train.csv
x, y	Numérica continua	Coordenadas de la esquina de la caja delimitadora (píxeles)
width, height	Numérica continua	Ancho y alto de la caja (píxeles)
slicenumber	Numérica discreta	Número del corte (slice) del volumen CT donde está la caja

Las dos tablas tienen granularidades distintas: **train.csv** es a nivel de **paciente/estudio** (2,019 filas), mientras que **trainboundingboxes.csv** es a nivel de **slice individual dentro de un estudio** (7,217 filas, con un promedio de ~ 30.7 cajas por estudio anotado). Solo el 11.6 % de los estudios tiene bounding boxes.

5.2. Resumen numérico y tablas de frecuencia

5.2.1. Variable objetivo: patientoverall

Clase	N° pacientes	Porcentaje
0 - Sin fractura	1,058	52.4 %
1 - Con fractura	961	47.6 %

La clase está razonablemente **balanceada** (52 %/48 %), lo cual favorece el entrenamiento de un clasificador binario sin necesidad de técnicas agresivas de balanceo.




Figura 2: Porcentaje de fractura por vértebra cervical.

5.2.2. Frecuencia de fractura por vértebra (C1–C7)

Vértebra	Nº fracturados	% del total
C1	146	7.2 %
C2	285	14.1 %
C3	73	3.6 %
C4	108	5.3 %
C5	162	8.0 %
C6	277	13.7 %
C7	393	19.5 %

Las fracturas **no se distribuyen uniformemente** entre vértebras. **C7** (19.5 %), **C2** (14.1 %) y **C6** (13.7 %) son las más afectadas, mientras que **C3** (3.6 %) es la menos afectada. Esto es clínicamente coherente: C2 y C7 son puntos de transición biomecánica (unión craneocervical y cervicotorácica) y concentran más traumatismos por fractura en la literatura médica real.

5.2.3. Número de vértebras fracturadas por paciente

La variable `nfracturas` se calcula como la suma de C1 a C7.

Estadístico	Valor
Media	0.72
Desviación estándar	0.94
Mínimo	0
Mediana (P50)	0
P75	1
Máximo	6

N° vértebras fracturadas	N° pacientes
0	1,058
1	623
2	239
3	64
4	26
5	7
6	2




Figura 3: Número de vértebras fracturadas por paciente.

La mayoría de los pacientes con fractura (623 de 961, $\sim 65\%$) tiene **una sola vértebra afectada**; los casos con múltiples vértebras fracturadas simultáneamente (3+) son poco frecuentes (99 pacientes, $\sim 5\%$ del total) — son los casos de trauma más severo.

5.2.4. Resumen numérico de las bounding boxes

Variable	Media	Desv. Est.	Mín	P25	Mediana	P75	Máx
x	203.9	51.9	50.1	168.6	202.0	237.0	371.8
y	181.8	61.6	22.1	139.0	180.0	225.0	377.0
width	100.9	54.9	11.0	57.6	89.3	133.7	313.7
height	78.8	42.9	10.6	47.4	70.0	99.0	367.0
slicenumber	191.1	94.6	26	128	173	234	483




Figura 4: Distribución de ancho (width) y alto (height) de las bounding boxes.

Las cajas tienen tamaños muy variables (ancho de 11 a 314 px), lo que sugiere que abarcan desde una sola vértebra hasta regiones más amplias de la columna. Su dispersión es alta ($CV > 50\%$), algo esperable dado que las vértebras cervicales varían de tamaño (C1/C2 son distintas anatómicamente de C6/C7) y las imágenes de distintos pacientes/equipos pueden tener campos de visión diferentes.

5.2.5. Cajas por estudio (solo estudios anotados)

Estadístico	Valor
N° de estudios con al menos 1 caja	235
Media de cajas por estudio	30.7
Mínimo	2
Mediana	24
Máximo	167




Figura 5: Distribución del número de bounding boxes (slices anotados) por estudio.

5.3. Cruce de variables clave

5.3.1. Consistencia entre patientoverall y la suma de C1–C7

Se verificó consistencia perfecta: **0 casos** con `patientoverall` = 0 y alguna vértebra marcada como fracturada, y **0 casos** con `patientoverall` = 1 sin ninguna vértebra marcada. Es decir, `patientoverall` es efectivamente 1 si y solo si `sum(C1..C7) > 0`. Esto confirma que las etiquetas son **internamente consistentes** (sin errores de codificación evidentes en esta relación).

5.3.2. Correlación entre vértebras fracturadas (co-ocurrencia)




Figura 6: Matriz de correlación (co-ocurrencia) entre fracturas de las 7 vértebras.

	C1	C2	C3	C4	C5	C6	C7
C1	1.00	0.19	0.03	-0.02	0.03	-0.03	-0.04
C2	0.19	1.00	0.10	-0.00	-0.04	-0.06	-0.08
C3	0.03	0.10	1.00	0.30	0.16	0.06	-0.00
C4	-0.02	-0.00	0.30	1.00	0.34	0.10	0.01
C5	0.03	-0.04	0.16	0.34	1.00	0.36	0.06
C6	-0.03	-0.06	0.06	0.10	0.36	1.00	0.28
C7	-0.04	-0.08	-0.00	0.01	0.06	0.28	1.00

El patrón de correlación es una **banda diagonal** — cada vértebra correlaciona más con sus vecinas inmediatas (ej. C4–C5: 0.34, C5–C6: 0.36, C3–C4: 0.30) que con vértebras lejanas (ej. C1–C7: -0.04, cercano a cero). Esto es clínicamente esperado: un trauma cervical suele afectar **segmentos contiguos** de la columna, no vértebras aisladas y distantes. Esta relación anatómica es útil para el modelado: un modelo podría beneficiarse de considerar la vecindad espacial entre vértebras.

5.3.3. Relación entre bounding boxes y severidad de la fractura




Figura 7: Promedio de bounding boxes por estudio según número de vértebras fracturadas.

N° vértebras fracturadas	Promedio de bboxes por estudio
0	0.0
1	2.8
2	7.9
3	24.8
4	50.0
5	75.6
6	83.0

El número promedio de bounding boxes crece de forma muy pronunciada con el número de vértebras fracturadas (de 0 en pacientes sanos hasta 83 en los pacientes con 6 vértebras fracturadas).

5.3.4. Presencia de bounding boxes vs diagnóstico general




Figura 8: Presencia de bounding boxes vs diagnóstico general (patientoverall).

	patientoverall = 0	patientoverall = 1	Total
Sin bbox	1,058	726	1,784
Con bbox	0	235	235

El 100 % de los estudios con bounding boxes tiene fractura (patientoverall=1), pero solo el 24.5 % de los pacientes con fractura (235 de 961) tiene bounding boxes anotadas. Ningún paciente sano (patientoverall=0) tiene bbox, lo cual es lógico (no hay nada que delimitar), pero implica que las bounding boxes **no cubren a todos los pacientes fracturados** — probablemente porque anotar manualmente cada corte de CT es muy costoso, y solo se etiquetó un subconjunto para entrenar/validar un detector de localización. Además, se observa que a **mayor severidad (más vértebras fracturadas), mayor probabilidad y cantidad de bboxes**, lo que sugiere que el subconjunto anotado no es aleatorio, sino que está **sesgado hacia los casos más severos o más claros de identificar**. Cualquier modelo que use bounding boxes como señal de entrenamiento debe considerar este sesgo de selección.

5.3.5. Distribución del corte anotado (slicenumber)




Figura 9: Distribución del slicenumber en las bounding boxes.

Los slices anotados se concentran principalmente entre 100 y 250 (mediana 173), lo que corresponde a la región donde normalmente se ubica la columna cervical dentro del volumen completo de la tomografía; hay una cola hacia valores altos (hasta 483) que representa estudios con mayor número de cortes totales o distinta reconstrucción.

6. Hallazgos y Conclusiones